

Algoritmos de Ordenação: *HeapSort*

ACH2002 - Introdução à Ciência da Computação II

Delano M. Beder

Escola de Artes, Ciências e Humanidades (EACH)
Universidade de São Paulo
dbeder@usp.br

10/2008

Material baseado em slides do professor Marcos Chaim

HeapSort

- *Heap* – Dicionário Merriam-Webster:
 - 1 Coleção de coisas jogadas uma em cima da outra – monte;
 - 2 Grande número ou grande quantidade – lote.
- Em computação, dois sentidos :
 - 1 Espaço de memória variável onde são criados objetos;
 - 2 Estrutura de dados para armazenar dados segundo uma regra particular
 - Próximo do sentido original, traduzido como *monte*.
- O algoritmo de ordenação *HeapSort* utiliza a estrutura de dados *heap* para ordenar um vetor.

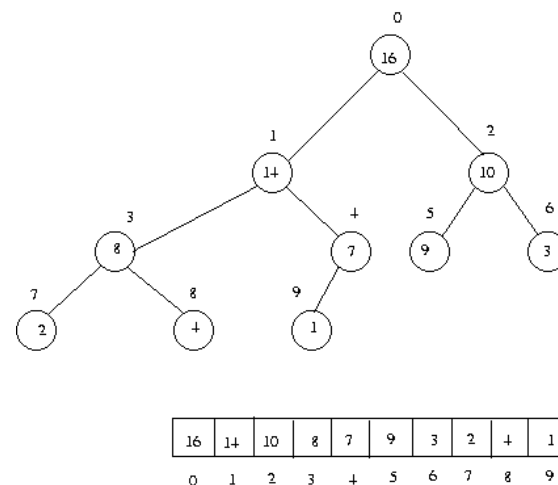
HeapSort

- O projeto por indução que leva ao *HeapSort* é essencialmente o mesmo do *Selection Sort*: selecionamos e posicionamos o maior (ou menor) elemento do conjunto e então aplicamos a hipótese de indução para ordenar os elementos restantes.
- A diferença importante é que no *HeapSort* utilizamos a estrutura de dados *heap* para selecionar o maior (ou menor) elemento eficientemente.
- Um *heap* é um vetor que simula uma árvore binária completa, a menos, talvez, do último nível, com estrutura de *heap*.

Estrutura Heap

Definição

A estrutura de dados *Heap* (binário) é um vetor que pode ser visto como uma árvore binária quase completa



- Cada nó da árvore corresponde a um elemento do vetor que armazena o valor no nó.
- A árvore está completamente preenchida em todos os níveis, exceto possivelmente no nível mais baixo, que é preenchido da esquerda para a direita até certo ponto.
- Um vetor V representa uma estrutura *heap* através de dois parâmetros:
 - 1 comprimento de V ($V.length$) – tamanho total do vetor;
 - 2 comprimento do *heap* ($heapComp$): comprimento da parte do vetor que contém elementos da estrutura *heap*.

Parâmetros da estrutura *heap*:

- Os elementos válidos para a estrutura do *heap* vão de 0 até $heapComp-1$.
- Portanto, $heapComp \leq V.length$.
- Os elementos de $heapComp$ até $V.length-1$ não fazem parte da estrutura *heap* mesmo sendo valores válidos.

A raiz da árvore representada na estrutura *heap* é $V[0]$. Dado um elemento da estrutura *heap* de índice i :

- $pai(i) : \lfloor (i-1)/2 \rfloor$
- $esquerda(i) : 2 * i + 1$
- $direita(i) : 2 * i + 2$

As operações para determinar o $pai(i)$, $esquerda(i)$ e $direita(i)$ podem ser implementadas muito rapidamente com operações sobre bits.

Há dois tipos de *heap* binário: *heap* máximo e *heap* mínimo.

Propriedades de *heap* máximo

- 1 $A[pai(i)] \geq A[i]$.
 - Isto é, o valor de um nó é no máximo o valor de seu pai.
- 2 O maior elemento do *heap* está na raiz.
- 3 as subárvores de um nó possuem valores menores ou iguais ao do nó.


Propriedades de *heap* mínimo

- 1 $A[pai(i)] \leq A[i]$.
 - Isto é, o valor de um nó é maior ou igual o valor de seu pai.
- 2 O menor elemento do *heap* está na raiz
- 3 as subárvores de um nó possuem valores maiores ou iguais ao do nó.

Definição

A altura de um nó em um *heap* é o número de arestas no caminho descendente simples mais longo desde o nó até uma folha.

- Qual a altura do nó de número 1 na figura abaixo ?
- Qual o nó de maior altura?



Teorema

A altura h de uma heap com n nós é $\lfloor \log_2 n \rfloor$.

- A altura é a mesma se o heap é completo (a última fileira está completa)
 - O número de nós n é dado por $n = 2^{h+1} - 1$
 - Ou seja, o número de nós n é tal que $2^h < n < 2^{h+1}$.
- Aplicando o logaritmo de 2 na inequação, obtém-se $h < \log_2 n < h + 1 \Rightarrow h = \lfloor \log_2 n \rfloor$.
- Ou se o heap é o mais incompleto possível (a última fileira possui um único elemento).
 - O número de nós n é dado por $2^h - 1 + 1$, ou seja, $n = 2^h$
 - A altura $h = \log_2 n \Rightarrow h = \lfloor \log_2 n \rfloor$.

- Toda manipulação de um heap deve manter a sua propriedade de heap (máximo ou mínimo) inalterada.
- Suponha a seguinte situação:
 - Um vetor V ;
 - Um índice i do vetor;
 - as árvores $\text{esquerda}(i)$ e $\text{direita}(i)$ são heaps máximos;
 - Devido a alguma alteração no heap, $V[i]$ pode ser menor que seus filhos
 - Violação da propriedade de heap máximo.
- Como manter a propriedade de heap máximo nessa situação?

Manutenção da propriedade de heap

A idéia para manter a propriedade de heap máximo é fazer $A[i]$ afundar no heap máximo.

```
void refazHeapMax(int V[], int i, int compHeap) {
    int esq, dir, maior, menor, temp;
    esq = esquerda(i); dir = direita(i);
    if(esq < compHeap && V[esq] > V[i]) {
        maior = esq;
    } else {
        maior = i;
    }
    if(dir < compHeap && V[dir] > V[maior]) {
        maior = dir;
    }
    if(maior != i) {
        // trocar V[i] <=> V[maior]
        temp = V[i];
        V[i] = V[maior];
        V[maior] = temp;
        // Ajusta a posicao de maior, se incorreta.
        refazHeapMax(V, maior, compHeap);
    }
}
```

Manutenção da propriedade de heap

- O tempo de execução do método `refazHeapMax()`:
 - 1 $\Theta(1)$ para corrigir os relacionamentos entre os elementos $A[i]$, $A[\text{esquerda}(i)]$ e $A[\text{direita}(i)]$.
 - 2 o tempo para executar `refazHeapMax()` em uma subárvore com raiz em um dos filhos do nó i .
- As subárvores de cada filho têm tamanho máximo $2n/3$
 - O pior caso ocorre quando a última linha da árvore está exatamente metade cheia.
- O tempo de execução de `refazHeapMax()` pode então ser descrito pela recorrência:

$$T(n) \leq T(2n/3) + \Theta(1) \Rightarrow T(n) = O(\log n)$$

- Como fazemos para transformar um vetor V de tamanho n em um heap?

Observação:

- Se o vetor *V* fosse um *heap* máximo então todos os elementos $V[\lfloor n/2 \rfloor] \dots V[n-1]$ seriam folhas. Por quê?
 - Imagine-se que $V[\lfloor n/2 \rfloor] \dots V[n-1]$ não fossem folhas.
 - Isto significa que $\exists V[k]$ tal que $\lfloor n/2 \rfloor \leq \text{pai}(k) \leq n-1$.
 - Neste caso, $k > n$, pois o $\text{pai}(k) = \lfloor k/2 \rfloor - 1$.
 - Porém, o comprimento do arranjo *V* é *n* ($V[0] \dots V[n-1]$).
 - Logo, *k* estaria fora do vetor e, portanto, não existe.

Partindo da idéia de que os elementos $V[\lfloor n/2 \rfloor - 1] \dots V[n-1]$ são *heaps* triviais (folhas):

- pode-se construir um *heap* chamando o método `refazMaxHeap()` para os elementos $V[\lfloor n/2 \rfloor - 1]$, $V[\lfloor n/2 \rfloor - 2]$ até $V[0]$ do arranjo.
- é como se imaginássemos que metade do arranjo são *heaps* triviais aos quais foram adicionados os elementos $V[\lfloor n/2 \rfloor - 1]$ até $V[0]$, sucessivamente.

Implementando a idéia anterior:

```
void constroiHeapMax(int [] V) {
    int compHeap = A.length;
    for(int i = (V.length)/2 - 1; i >= 0 ; i--)
        refazHeapMax(V, i, compHeap);
}
```

Pode não parecer, mas o custo do método acima é $O(n)$.

(Ver [2], página 109).

Exemplo

`int v[] = {16, 4, 10, 14, 7, 9, 3, 2, 8, 1}` é um *heap* ?

O algoritmo *HeapSort* (ordenação por monte) utiliza os métodos `constroiHeapMax()` e `refazHeapMax()`:

```
HeapSort
void heapSort(int V[]) {
    int i, compHeap, temp;
    // Constrói o heap máximo do arranjo todo
    compHeap = V.length;
    constroiHeapMax(V);

    for(i = V.length-1; i > 0; --i) {
        // Troca V[0] <=> V[i]
        temp = V[0];
        V[0] = V[i];
        V[i] = temp;
        // Diminui o heap, pois V[i] está posicionado
        compHeap--;
        refazHeapMax(V, 0, compHeap);
    }
}
```

Comentários:

- O *HeapSort* começa com uma chamada ao método `constroiHeapMax()` para o vetor *V* todo ($V[0] \dots V[n-1]$).
- O maior elemento está em $V[0]$ depois de chamado `constroiHeapMax()`.
- Então é feita a troca $V[0]$ e $V[n-1]$.
- Agora o subvetor $V[0 \dots n-2]$ precisa ser mantido, pois $V[0]$ foi alterado com a troca realizada e a propriedade de *heap* máximo pode ter sido violada.
- O método `refazHeapMaximo()` é então chamado com diminuição do tamanho do *heap* decrementado — afinal $V[n-1]$ já não faz parte, pois já contém o maior valor.

O custo do algoritmo *HeapSort* é $O(n \log n)$ porque:

- 1 `constroiHeapMax()` custa $O(n)$.
- 2 cada uma das $(n-1)$ chamadas para o método `refazHeapMax()` custa $O(\log n)$.
- 3 Portanto, custo total do *HeapSort* é:

$$T(n) = O(n) + (n - 1)O(\log n) = O(n \log n)$$

- Estrutura *heap*:
 - `pai(i)`: $\lfloor (i-1)/2 \rfloor$
 - `esquerda(i)`: $2i+1$
 - `direita(i)`: $2i+2$
- Propriedade *heap* máximo: $A[\text{pai}(i)] \geq A[i]$.
- Propriedade *heap* mínimo: $A[\text{pai}(i)] \leq A[i]$.
- `refazHeapMax()`: $O(\log n)$.
- `constroiHeapMax()`: $O(n)$.
- `HeapSort()`: $O(n \log n)$.

Exercícios

- 1 Onde em um *heap* máximo o menor elemento poderia residir, supondo-se que todos os elementos sejam distintos?
- 2 A seqüência $\langle 23, 17, 14, 6, 13, 10, 1, 5, 7, 12 \rangle$ é um *heap* máximo?
- 3 Usando a Figura 1 como modelo, ilustre a operação de `refazHeapMax(A, 3)` sobre o vetor $V = \langle 27, 17, 3, 16, 13, 10, 1, 5, 7, 12, 4, 8, 9, 0 \rangle$.
- 4 Escreva um método em Java `refazHeapMin()` que refaz um *heap* mínimo.
- 5 Qual é o efeito de chamar `refazHeapMax(V, i)` quando $V[i]$ é maior que seus filhos?
- 6 Qual é o efeito de chamar `refazHeapMax(V, i)` quando $i > \text{compHeap}/2$?
- 7 Siga a operação do algoritmo *HeapSort* sobre o arranjo $A = \langle 5, 13, 2, 25, 7, 17, 20, 8, 4 \rangle$.

Referências

- [1] Thomas H. Cormen, Charles E. Leiserson, Ronald L. Rivest & Clifford Stein. *Algoritmos - Tradução da 2a. Edição Americana*. Editora Campus, 2002.
- [2] Nívio Ziviani. *Projeto de Algoritmos com implementações em C e Pascal*. Editora Thomson, 2a. Edição, 2004.

Importante

Ao ler a referência [2] (páginas 103-111) atentar para o detalhe de que os vetores V de comprimento n variam de $V[1]$ até $V[n]$. Os algoritmos apresentados nestes slides utilizam a notação de Java, ou seja, variação de $V[0]$ até $V[n-1]$. Por isso, prestar atenção nas diferenças de notação ao ler a referência [2].