

Inferência Estatística

Introdução

E.F.T¹

¹EACH-USP
Universidade de São Paulo

ACH2053

Outline

- 1 Relembrando Amostras Aleatórias
 - Definição de a.a.
 - Exemplos de a.a.
- 2 Estatísticas Suficientes
 - Estatísticas Suficientes
 - Limitações no uso de estatísticas suficientes
 - Limitações no uso de estatísticas suficientes
- 3 Estimadores Não Viesados
 - Estimadores Não Viesados

Outline

- 1 Relembrando Amostras Aleatórias
 - Definição de a.a.
 - Exemplos de a.a.
- 2 Estatísticas Suficientes
 - Estatísticas Suficientes
 - Limitações no uso de estatísticas suficientes
 - Limitações no uso de estatísticas suficientes
- 3 Estimadores Não Viesados
 - Estimadores Não Viesados

Definição de a.a.

As variáveis aleatórias X_1, \dots, X_n são chamada de *amostra aleatória* de tamanho n da população com distribuição $f(x|\theta)$ se:

- as variáveis X_1, \dots, X_n são mutuamente independentes e
- a f.d.p. ou f.p. de cada marginal X_i for a mesma ($f(x_i|\theta)$) para cada $i = 1, \dots, n$.

A partir da definição acima, a f.d.p. conjunta ou a f.p. conjunta de X_1, \dots, X_n é dada por

$$f(X_1, \dots, X_n|\theta) = f(\mathbf{X}|\theta) = f(X_1|\theta) \dots f(X_n|\theta) = \prod_{i=1}^n f(X_i|\theta) \quad (1)$$

Definição de a.a.

As variáveis aleatórias X_1, \dots, X_n são chamada de *amostra aleatória* de tamanho n da população com distribuição $f(x|\theta)$ se:

- as variáveis X_1, \dots, X_n são mutuamente independentes e
- a f.d.p. ou f.p. de cada marginal X_i for a mesma ($f(x_i|\theta)$) para cada $i = 1, \dots, n$.

A partir da definição acima, a f.d.p. conjunta ou a f.p.conjunta de X_1, \dots, X_n é dada por

$$f(X_1, \dots, X_n|\theta) = f(\mathbf{X}|\theta) = f(X_1|\theta) \dots f(X_n|\theta) = \prod_{i=1}^n f(X_i|\theta) \quad (1)$$

Outline

- 1 Relembrando Amostras Aleatórias
 - Definição de a.a.
 - Exemplos de a.a.
- 2 Estatísticas Suficientes
 - Estatísticas Suficientes
 - Limitações no uso de estatísticas suficientes
 - Limitações no uso de estatísticas suficientes
- 3 Estimadores Não Viesados
 - Estimadores Não Viesados

Amostragem de uma Bernoulli

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição de Bernoulli com parâmetro desconhecido θ ($0 \leq \theta \leq 1$). Para quaisquer valores observados x_1, \dots, x_n onde a f.p. de cada x_i é:

$$f(x_i|\theta) = \theta^{x_i}(1 - \theta)^{1-x_i}$$

onde x_i só pode ser 0 ou 1.

Desta forma, a f.p.conjunta de x_1, \dots, x_n será:

$$f(x_1, \dots, x_n|\theta) = f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \prod_{i=1}^n \theta^{x_i}(1 - \theta)^{1-x_i}$$

Se denotarmos por $y = \sum_{i=1}^n x_i$ teremos:

$$f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} = \theta^y (1 - \theta)^{n-y}$$

Amostragem de uma Bernoulli

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição de Bernoulli com parâmetro desconhecido θ ($0 \leq \theta \leq 1$). Para quaisquer valores observados x_1, \dots, x_n onde a f.p. de cada x_i é:

$$f(x_i|\theta) = \theta^{x_i}(1 - \theta)^{1-x_i}$$

onde x_i só pode ser 0 ou 1.

Desta forma, a f.p.conjunta de x_1, \dots, x_n será:

$$f(x_1, \dots, x_n|\theta) = f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \prod_{i=1}^n \theta^{x_i}(1 - \theta)^{1-x_i}$$

Se denotarmos por $y = \sum_{i=1}^n x_i$ teremos:

$$f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} = \theta^y (1 - \theta)^{n-y}$$

Amostragem de uma Bernoulli

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição de Bernoulli com parâmetro desconhecido θ ($0 \leq \theta \leq 1$). Para quaisquer valores observados x_1, \dots, x_n onde a f.p. de cada x_i é:

$$f(x_i|\theta) = \theta^{x_i}(1 - \theta)^{1-x_i}$$

onde x_i só pode ser 0 ou 1.

Desta forma, a f.p.conjunta de x_1, \dots, x_n será:

$$f(x_1, \dots, x_n|\theta) = f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \prod_{i=1}^n \theta^{x_i}(1 - \theta)^{1-x_i}$$

Se denotarmos por $y = \sum_{i=1}^n x_i$ teremos:

$$f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} = \theta^y (1 - \theta)^{n-y}$$

Amostragem de uma Uniforme

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição Uniforme no intervalo $(0, \theta)$ com parâmetro desconhecido θ ($\theta > 0$). Para quaisquer valores observados x_1, \dots, x_n onde a f.d.p. de cada x_i é:

$$f(x_i|\theta) = \begin{cases} \frac{1}{\theta} & \text{para } 0 \leq x_i \leq \theta \\ 0 & \text{c.c} \end{cases}$$

Desta forma, a f.d.p.conjunta de x_1, \dots, x_n será:

$$f(x_1, \dots, x_n|\theta) = f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \begin{cases} \frac{1}{\theta^n} & \text{para } 0 \leq x_i \leq \theta \\ 0 & \text{c.c} \end{cases}$$

Amostragem de uma Uniforme

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição Uniforme no intervalo $(0, \theta)$ com parâmetro desconhecido θ ($\theta > 0$). Para quaisquer valores observados x_1, \dots, x_n onde a f.d.p. de cada x_i é:

$$f(x_i|\theta) = \begin{cases} \frac{1}{\theta} & \text{para } 0 \leq x_i \leq \theta \\ 0 & \text{c.c} \end{cases}$$

Desta forma, a f.d.p.conjunta de x_1, \dots, x_n será:

$$f(x_1, \dots, x_n|\theta) = f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \begin{cases} \frac{1}{\theta^n} & \text{para } 0 \leq x_i \leq \theta \\ 0 & \text{c.c} \end{cases}$$

Amostragem de uma Uniforme

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição Uniforme no intervalo $(0, \theta)$ com parâmetro desconhecido θ ($\theta > 0$). Para quaisquer valores observados x_1, \dots, x_n onde a f.d.p. de cada x_i é:

$$f(x_i|\theta) = \begin{cases} \frac{1}{\theta} & \text{para } 0 \leq x_i \leq \theta \\ 0 & \text{c.c} \end{cases}$$

Desta forma, a f.d.p.conjunta de x_1, \dots, x_n será:

$$f(x_1, \dots, x_n|\theta) = f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \begin{cases} \frac{1}{\theta^n} & \text{para } 0 \leq x_i \leq \theta \\ 0 & \text{c.c} \end{cases}$$

Amostragem de uma Uniforme

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição Uniforme no intervalo $(0, \theta)$ com parâmetro desconhecido θ ($\theta > 0$). Para quaisquer valores observados x_1, \dots, x_n onde a f.d.p. de cada x_i é:

$$f(x_i|\theta) = \begin{cases} \frac{1}{\theta} & \text{para } 0 \leq x_i \leq \theta \\ 0 & \text{c.c} \end{cases}$$

Desta forma, a f.d.p.conjunta de x_1, \dots, x_n será:

$$f(x_1, \dots, x_n|\theta) = f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \begin{cases} \frac{1}{\theta^n} & \text{para } 0 \leq x_i \leq \theta \\ 0 & \text{c.c} \end{cases}$$

Amostragem de uma Poisson

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição de Poisson com parâmetro desconhecido θ ($\theta > 0$). Para quaisquer valores observados x_1, \dots, x_n onde a f.p. de cada x_i é:

$$f(x_i|\theta) = \frac{e^{-\theta} \theta^{x_i}}{x_i!}$$

onde x_i pode assumir valores inteiros

Desta forma, a f.p.conjunta de x_1, \dots, x_n será:

$$f(x_1, \dots, x_n|\theta) = f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \prod_{i=1}^n \frac{e^{-\theta} \theta^{x_i}}{x_i!}$$

Se denotarmos por $y = \sum_{i=1}^n x_i$ teremos:

$$f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \left(\prod_{i=1}^n \frac{1}{x_i!}\right) e^{-n\theta} \theta^{\sum_{i=1}^n x_i} = \left(\prod_{i=1}^n \frac{1}{x_i!}\right) e^{-n\theta} \theta^y$$

Amostragem de uma Poisson

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição de Poisson com parâmetro desconhecido θ ($\theta > 0$). Para quaisquer valores observados x_1, \dots, x_n onde a f.p. de cada x_i é:

$$f(x_i|\theta) = \frac{e^{-\theta} \theta^{x_i}}{x_i!}$$

onde x_i pode assumir valores inteiros

Desta forma, a f.p.conjunta de x_1, \dots, x_n será:

$$f(x_1, \dots, x_n|\theta) = f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \prod_{i=1}^n \frac{e^{-\theta} \theta^{x_i}}{x_i!}$$

Se denotarmos por $y = \sum_{i=1}^n x_i$ teremos:

$$f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \left(\prod_{i=1}^n \frac{1}{x_i!} \right) e^{-n\theta} \theta^{\sum_{i=1}^n x_i} = \left(\prod_{i=1}^n \frac{1}{x_i!} \right) e^{-n\theta} \theta^y$$

Amostragem de uma Poisson

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição de Poisson com parâmetro desconhecido θ ($\theta > 0$). Para quaisquer valores observados x_1, \dots, x_n onde a f.p. de cada x_i é:

$$f(x_i|\theta) = \frac{e^{-\theta} \theta^{x_i}}{x_i!}$$

onde x_i pode assumir valores inteiros

Desta forma, a f.p.conjunta de x_1, \dots, x_n será:

$$f(x_1, \dots, x_n|\theta) = f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \prod_{i=1}^n \frac{e^{-\theta} \theta^{x_i}}{x_i!}$$

Se denotarmos por $y = \sum_{i=1}^n x_i$ teremos:

$$f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \left(\prod_{i=1}^n \frac{1}{x_i!} \right) e^{-n\theta} \theta^{\sum_{i=1}^n x_i} = \left(\prod_{i=1}^n \frac{1}{x_i!} \right) e^{-n\theta} \theta^y$$

Amostragem de uma Exponencial

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição Exponencial com parâmetro desconhecido θ ($\theta > 0$). Para quaisquer valores observados x_1, \dots, x_n onde a f.d.p. de cada x_i é:

$$f(x_i|\theta) = \theta e^{-\theta x_i}$$

Desta forma, a f.d.p.conjunta de x_1, \dots, x_n será:

$$f(x_1, \dots, x_n|\theta) = f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \prod_{i=1}^n \theta e^{-\theta x_i}$$

Se denotarmos por $y = \sum_{i=1}^n x_i$ teremos:

$$f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \theta^n e^{-\theta \sum_{i=1}^n x_i} = \theta^n e^{-\theta y}$$

Amostragem de uma Exponencial

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição Exponencial com parâmetro desconhecido θ ($\theta > 0$). Para quaisquer valores observados x_1, \dots, x_n onde a f.d.p. de cada x_i é:

$$f(x_i|\theta) = \theta e^{-\theta x_i}$$

Desta forma, a f.d.p.conjunta de x_1, \dots, x_n será:

$$f(x_1, \dots, x_n|\theta) = f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \prod_{i=1}^n \theta e^{-\theta x_i}$$

Se denotarmos por $y = \sum_{i=1}^n x_i$ teremos:

$$f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \theta^n e^{-\theta \sum_{i=1}^n x_i} = \theta^n e^{-\theta y}$$

Amostragem de uma Exponencial

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição Exponencial com parâmetro desconhecido θ ($\theta > 0$). Para quaisquer valores observados x_1, \dots, x_n onde a f.d.p. de cada x_i é:

$$f(x_i|\theta) = \theta e^{-\theta x_i}$$

Desta forma, a f.d.p.conjunta de x_1, \dots, x_n será:

$$f(x_1, \dots, x_n|\theta) = f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \prod_{i=1}^n \theta e^{-\theta x_i}$$

Se denotarmos por $y = \sum_{i=1}^n x_i$ teremos:

$$f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \theta^n e^{-\theta \sum_{i=1}^n x_i} = \theta^n e^{-\theta y}$$

Amostragem de uma Normal

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição Normal com média desconhecido θ ($-\infty < \theta < \infty$) e variância σ^2 conhecida. Para quaisquer valores observados x_1, \dots, x_n onde a f.d.p. de cada x_i é:

$$f(x_i|\theta) = \frac{1}{(2\pi)^{1/2}\sigma} e^{-\frac{(x_i-\theta)^2}{2\sigma^2}}$$

para $-\infty < x_i < \infty$.

Desta forma, a f.d.p.conjunta de x_1, \dots, x_n será:

$$f(x_1, \dots, x_n|\theta) = f_n(\mathbf{x}|\theta) = \prod_{i=1}^n \frac{1}{(2\pi)^{1/2}\sigma} e^{-\frac{(x_i-\theta)^2}{2\sigma^2}} \quad (2)$$

Amostragem de uma Normal

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição Normal com média desconhecido θ ($-\infty < \theta < \infty$) e variância σ^2 conhecida. Para quaisquer valores observados x_1, \dots, x_n onde a f.d.p. de cada x_i é:

$$f(x_i|\theta) = \frac{1}{(2\pi)^{1/2}\sigma} e^{[-\frac{(x_i-\theta)^2}{2\sigma^2}]}$$

para $-\infty < x_i < \infty$.

Desta forma, a f.d.p.conjunta de x_1, \dots, x_n será:

$$f(x_1, \dots, x_n|\theta) = f_n(\mathbf{x}|\theta) = \prod_{i=1}^n \frac{1}{(2\pi)^{1/2}\sigma} e^{[-\frac{(x_i-\theta)^2}{2\sigma^2}]} \quad (2)$$

Amostragem de uma Normal

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição Normal com média desconhecido θ ($-\infty < \theta < \infty$) e variância σ^2 conhecida. Para quaisquer valores observados x_1, \dots, x_n onde a f.d.p. de cada x_i é:

$$f(x_i|\theta) = \frac{1}{(2\pi)^{1/2}\sigma} e^{-\frac{(x_i-\theta)^2}{2\sigma^2}}$$

para $-\infty < x_i < \infty$.

Desta forma, a f.d.p.conjunta de x_1, \dots, x_n será:

$$f(x_1, \dots, x_n|\theta) = f_n(\mathbf{x}|\theta) = \prod_{i=1}^n \frac{1}{(2\pi)^{1/2}\sigma} e^{-\frac{(x_i-\theta)^2}{2\sigma^2}} \quad (2)$$

Amostragem de uma Gamma

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição Gamma com parâmetros α e β com ($\alpha > 0$ e $\beta > 0$). Para quaisquer valores observados x_1, \dots, x_n onde a f.d.p. de cada x_i é:

$$f(x_i|\alpha, \beta) = \begin{cases} \frac{\beta^\alpha}{\Gamma(\alpha)} x_i^{\alpha-1} e^{-\beta x_i} & \text{para } x > 0 \\ 0 & \text{para } x \leq 0 \end{cases} \quad (3)$$

Sabe-se que para esta distribuição, o valor esperado e a variância para qualquer variável X_i é

$$E[X] = \frac{\alpha}{\beta} \quad (4)$$

$$Var(X) = \frac{\alpha}{\beta^2} \quad (5)$$

Amostragem de uma Gamma

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição Gamma com parâmetros α e β com ($\alpha > 0$ e $\beta > 0$). Para quaisquer valores observados x_1, \dots, x_n onde a f.d.p. de cada x_i é:

$$f(x_i|\alpha, \beta) = \begin{cases} \frac{\beta^\alpha}{\Gamma(\alpha)} x_i^{\alpha-1} e^{-\beta x_i} & \text{para } x > 0 \\ 0 & \text{para } x \leq 0 \end{cases} \quad (3)$$

Sabe-se que para esta distribuição, o valor esperado e a variância para qualquer variável X_i é

$$E[X] = \frac{\alpha}{\beta} \quad (4)$$

$$Var(X) = \frac{\alpha}{\beta^2} \quad (5)$$

Amostragem de uma Gamma

Desta forma, a f.d.p.conjunta de x_1, \dots, x_n será:

$$\begin{aligned} f(x_1, \dots, x_n | \theta) &= f_n(\mathbf{x} | \theta) \\ &= \prod_{i=1}^n \frac{\beta^\alpha}{\Gamma(\alpha)} x_i^{\alpha-1} e^{-\beta x_i} \\ &= \frac{\beta^{n\alpha}}{\Gamma^n(\alpha)} (\prod_{i=1}^n x_i)^{\alpha-1} e^{-\beta \sum_{i=1}^n x_i} \end{aligned} \quad (6)$$

Amostragem de uma Gamma

Desta forma, a f.d.p.conjunta de x_1, \dots, x_n será:

$$\begin{aligned} f(x_1, \dots, x_n | \theta) &= f_n(\mathbf{x} | \theta) \\ &= \prod_{i=1}^n \frac{\beta^\alpha}{\Gamma(\alpha)} x_i^{\alpha-1} e^{-\beta x_i} \\ &= \frac{\beta^{n\alpha}}{\Gamma^n(\alpha)} (\prod_{i=1}^n x_i)^{\alpha-1} e^{-\beta \sum_{i=1}^n x_i} \end{aligned} \quad (6)$$

Amostragem de uma Gamma

Desta forma, a f.d.p.conjunta de x_1, \dots, x_n será:

$$\begin{aligned} f(x_1, \dots, x_n | \theta) &= f_n(\mathbf{x} | \theta) \\ &= \prod_{i=1}^n \frac{\beta^\alpha}{\Gamma(\alpha)} x_i^{\alpha-1} e^{-\beta x_i} \\ &= \frac{\beta^{n\alpha}}{\Gamma^n(\alpha)} (\prod_{i=1}^n x_i)^{\alpha-1} e^{-\beta \sum_{i=1}^n x_i} \end{aligned} \quad (6)$$

Amostragem de uma Beta

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição Beta com parâmetros α e β com ($\alpha > 0$ e $\beta > 0$). Para quaisquer valores observados x_1, \dots, x_n a f.d.p. de cada x_i é:

$$f(x_i|\alpha, \beta) = \begin{cases} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} x_i^{\alpha-1} (1-x_i)^{\beta-1} & \text{para } 0 < x < 1 \\ 0 & \text{c.c} \end{cases} \quad (7)$$

Sabe-se que para esta distribuição, o valor esperado e a variância para qualquer variável X_i é

$$E[X] = \frac{\alpha}{\alpha + \beta} \quad (8)$$

$$Var(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)} \quad (9)$$

Amostragem de uma Beta

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição Beta com parâmetros α e β com ($\alpha > 0$ e $\beta > 0$). Para quaisquer valores observados x_1, \dots, x_n a f.d.p. de cada x_i é:

$$f(x_i|\alpha, \beta) = \begin{cases} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} x_i^{\alpha-1} (1-x_i)^{\beta-1} & \text{para } 0 < x < 1 \\ 0 & \text{c.c} \end{cases} \quad (7)$$

Sabe-se que para esta distribuição, o valor esperado e a variância para qualquer variável X_i é

$$E[X] = \frac{\alpha}{\alpha + \beta} \quad (8)$$

$$Var(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)} \quad (9)$$

Outline

- 1 Relembrando Amostras Aleatórias
 - Definição de a.a.
 - Exemplos de a.a.
- 2 Estatísticas Suficientes
 - Estatísticas Suficientes
 - Limitações no uso de estatísticas suficientes
 - Limitações no uso de estatísticas suficientes
- 3 Estimadores Não Viesados
 - Estimadores Não Viesados

Definição de Estatística

As v.a. X_1, \dots, X_n formam uma a.a. Sabe-se que a sua distribuição conjunta $f_n(\mathbf{x}|\theta)$ tem a seguinte forma para algum valor particular de $\theta \in \Omega$:

$$f_n(\mathbf{x}|\theta) = f(x_1|\theta) \dots f(x_n|\theta) \quad (10)$$

Em outras palavras, sabe-se que a conjunta de X_1, \dots, X_n é membro da família que contém todas as f.d.p do tipo $f_n(\mathbf{x}|\theta)$ para todos os possíveis valores de $\theta \in \Omega$. O problema de estimar o valor de θ pode ser visto como a seleção por inferência de uma particular distribuição nesta família que gerou as observações X_1, \dots, X_n .

Definição de Estatística

Qualquer função a valores reais $T = r(X_1, \dots, X_n)$ das observações na a.a. é chamada de *estatística*.

As estatísticas mais comuns são:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i : \text{ Média da amostra}$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 : \text{ Variância da amostra}$$

$$X_{(1)} = \min(X_1, \dots, X_n) : \text{ o menor valor da amostra}$$

$$X_{(n)} = \max(X_1, \dots, X_n) : \text{ o maior valor da amostra}$$

$$X_{(i)} = \text{ i-ésima maior observação da amostra}$$

Definição de Estatística

Qualquer função a valores reais $T = r(X_1, \dots, X_n)$ das observações na a.a. é chamada de *estatística*.

As estatísticas mais comuns são:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i : \text{ Média da amostra}$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 : \text{ Variância da amostra}$$

$$X_{(1)} = \min(X_1, \dots, X_n) : \text{ o menor valor da amostra}$$

$$X_{(n)} = \max(X_1, \dots, X_n) : \text{ o maior valor da amostra}$$

$$X_{(i)} = \text{ i-ésima maior observação da amostra}$$

Definição de Estatística

Para qualquer valor fixado de $\theta \in \Omega$, a distribuição de qualquer estatística T pode ser derivada da conjunta de X_1, \dots, X_n .

Em geral, esta distribuição dependerá de θ , desta maneira, haverá uma família de distribuições para T correspondentes aos diferentes possíveis valores de $\theta \in \Omega$.

Definição de Estatística

Para qualquer valor fixado de $\theta \in \Omega$, a distribuição de qualquer estatística T pode ser derivada da conjunta de X_1, \dots, X_n .
Em geral, esta distribuição dependerá de θ , desta maneira, haverá uma família de distribuições para T correspondentes aos diferentes possíveis valores de $\theta \in \Omega$.

Definição de Estatística Suficiente

Se dois indivíduos A e B devem estimar o valor de um parâmetro θ , A pode observar os valores de X_1, \dots, X_n e B não pode observar os mesmos, mas apenas o valor de certa estatística $T = r(X_1, \dots, X_n)$.

Em geral A será capaz de achar melhores estimadores do que B pois pode escolher qualquer função das observações X_1, \dots, X_n como estimador de θ .

Definição de Estatística Suficiente

Se dois indivíduos A e B devem estimar o valor de um parâmetro θ , A pode observar os valores de X_1, \dots, X_n e B não pode observar os mesmos, mas apenas o valor de certa estatística $T = r(X_1, \dots, X_n)$.

Em geral A será capaz de achar melhores estimadores do que B pois pode escolher qualquer função das observações X_1, \dots, X_n como estimador de θ .

Definição de Estatística Suficiente

Se dois indivíduos A e B devem estimar o valor de um parâmetro θ , A pode observar os valores de X_1, \dots, X_n e B não pode observar os mesmos, mas apenas o valor de certa estatística $T = r(X_1, \dots, X_n)$.

Em geral A será capaz de achar melhores estimadores do que B pois pode escolher qualquer função das observações X_1, \dots, X_n como estimador de θ .

Definição de Estatística Suficiente

No entanto, algumas vezes B será capaz de estimar como A. Em esse problema, a função $T = r(X_1, \dots, X_n)$ em algum sentido, sumariza toda a informação contida na a.a. tal que o conhecimento dos valores individuais de X_1, \dots, X_n será irrelevante na busca de um bom estimador de θ . A estatística T tendo esta propriedade é chamada de *estatística suficiente*.

Definição de Estatística Suficiente

Formalmente, se T é uma estatística e t é um valor particular de T , então a distribuição condicional de X_1, \dots, X_n dado que $T = t$, pode ser calculada da equação 10 que em geral depende de θ . Desta forma, para cada valor de t existe uma família de possíveis distribuições condicionais correspondentes aos diferentes valores possíveis de $\theta \in \Omega$. Poderia acontecer no entanto, que para cada valor de t , a distribuição condicional de X_1, \dots, X_n dado que $T = t$ é a mesma para todos os valores de θ . Neste caso, é dito que T é uma *estatística suficiente para o parâmetro θ* .

Definição de Estatística Suficiente

Uma estatística suficiente T é considerada uma sumarização de toda a informação relevante sobre θ contida na amostra X_1, \dots, X_n . Se o indivíduo B pode observar T (e T é uma estatística suficiente) e não os valores individuais de X_1, \dots, X_n , então, a distribuição condicional de X_1, \dots, X_n dado que $T = t$ é completamente conhecida para qualquer valor observado t e não depende do valor desconhecido θ . Portanto, para qualquer valor de t que poderia ser observado, o indivíduo B pode gerar n variáveis aleatórias X'_1, \dots, X'_n de acordo com esta distribuição condicional conjunta. Este processo de gerar as variáveis X'_1, \dots, X'_n é chamado de *aleatorização auxiliar*.

Definição de Estatística Suficiente

Quando é observado T e logo gerado X'_1, \dots, X'_n de acordo com uma especificada distribuição condicional conjunta, segue que para qualquer valor de $\theta \in \Omega$, a marginal conjunta de X'_1, \dots, X'_n será a mesma da conjunta X_1, \dots, X_n .

A diferença entre uma estatística suficiente de uma não suficiente pode ser explicado da seguinte forma: A *aleatorização auxiliar* usada para gerar as variáveis X'_1, \dots, X'_n após a observação da estatística suficiente T não requer conhecimento sobre o valor de θ . Se T não for suficiente, a *aleatorização auxiliar* poderia não acontecer, pois a distribuição condicional conjunta de X_1, \dots, X_n para um dado valor de T envolve o valor de θ e este valor é desconhecido.

Definição de Estatística Suficiente

Quando é observado T e logo gerado X'_1, \dots, X'_n de acordo com uma especificada distribuição condicional conjunta, segue que para qualquer valor de $\theta \in \Omega$, a marginal conjunta de X'_1, \dots, X'_n será a mesma da conjunta X_1, \dots, X_n .

A diferença entre uma estatística suficiente de uma não suficiente pode ser explicado da seguinte forma: A *aleatorização auxiliar* usada para gerar as variáveis X'_1, \dots, X'_n após a observação da estatística suficiente T não requer conhecimento sobre o valor de θ . Se T não for suficiente, a *aleatorização auxiliar* poderia não acontecer, pois a distribuição condicional conjunta de X_1, \dots, X_n para um dado valor de T envolve o valor de θ e este valor é desconhecido.

Definição de Estatística Suficiente

Suponha que o indivíduo A quem observa os valores de X_1, \dots, X_n planeja usar um estimador particular $\delta(X_1, \dots, X_n)$ para estimar θ , e B observa o valor de T e gera X'_1, \dots, X'_n que tem a mesma distribuição conjunta de X_1, \dots, X_n . Portanto, se B usa o estimador $\delta(X'_1, \dots, X'_n)$, segue que a distribuição de probabilidade do estimador de B será a mesma da distribuição de probabilidade do estimador de A.

Critério de Fatorização

Seja X_1, \dots, X_n uma a.a de uma distribuição com f.d.p ou f.p $f(x|\theta)$, onde $\theta \in \Omega$ é desconhecido. Uma estatística $T = r(X_1, \dots, X_n)$ é suficiente para θ se e somente se a distribuição conjunta $f_n(\mathbf{x}|\theta)$ pode ser fatorada como segue para todos os valores de $\mathbf{x} = (x_1, \dots, x_n)$ e todos os valores de $\theta \in \Omega$:

$$f_n(\mathbf{x}|\theta) = \mathbf{u}(\mathbf{x})v[r(\mathbf{x}), \theta] \quad (11)$$

\mathbf{u} depende de \mathbf{x} mas não de θ e a função v depende de θ mas a dependência é nos valores observados \mathbf{x} a través da estatística $r(\mathbf{x})$.

Exemplo: Amostragem de uma Distribuição de Poisson

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição de Poisson com média θ desconhecida ($\theta > 0$). Mostraremos que $T = \sum_{i=1}^n X_i$ é uma estatística suficiente para θ .

Para qualquer conjunto de inteiros não negativos x_1, \dots, x_n a f.p conjunta $f_n(\mathbf{x}|\theta)$ de X_1, \dots, X_n é:

$$f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \left(\prod_{i=1}^n \frac{1}{x_i!}\right) e^{-n\theta} \theta^{\sum_{i=1}^n x_i} = \left(\prod_{i=1}^n \frac{1}{x_i!}\right) e^{-n\theta} \theta^y$$

onde $y = \sum_{i=1}^n x_i$.

Exemplo: Amostragem de uma Distribuição de Poisson

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição de Poisson com média θ desconhecida ($\theta > 0$). Mostraremos que $T = \sum_{i=1}^n X_i$ é uma estatística suficiente para θ .

Para qualquer conjunto de inteiros não negativos x_1, \dots, x_n a f.p conjunta $f_n(\mathbf{x}|\theta)$ de X_1, \dots, X_n é:

$$f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \left(\prod_{i=1}^n \frac{1}{x_i!}\right) e^{-n\theta} \theta^{\sum_{i=1}^n x_i} = \left(\prod_{i=1}^n \frac{1}{x_i!}\right) e^{-n\theta} \theta^y$$

onde $y = \sum_{i=1}^n x_i$.

Exemplo: Amostragem de uma Distribuição de Poisson

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição de Poisson com média θ desconhecida ($\theta > 0$). Mostraremos que $T = \sum_{i=1}^n X_i$ é uma estatística suficiente para θ .

Para qualquer conjunto de inteiros não negativos x_1, \dots, x_n a f.p conjunta $f_n(\mathbf{x}|\theta)$ de X_1, \dots, X_n é:

$$f_n(\mathbf{x}|\theta) = \prod_{i=1}^n f(x_i|\theta) = \left(\prod_{i=1}^n \frac{1}{x_i!}\right) e^{-n\theta} \theta^{\sum_{i=1}^n x_i} = \left(\prod_{i=1}^n \frac{1}{x_i!}\right) e^{-n\theta} \theta^y$$

onde $y = \sum_{i=1}^n x_i$.

Exemplo: Amostragem de uma Distribuição de Poisson

Pode-se ver que $f_n(\mathbf{x}|\theta)$ pode ser expressado como a equação 11 como o produto de uma função que não depende de θ e uma função que depende de θ mas esta dependência é no vetor observado \mathbf{x} através do valor de y . Segue que $T = \sum_{i=1}^n X_i$ é uma estatística suficiente para θ .

Exemplo: Amostragem de uma Distribuição contínua

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição contínua com a seguinte f.d.p.

$$f(x|\theta) = \begin{cases} \theta x^{\theta-1} & \text{para } 0 < x < 1 \\ 0 & \text{c.c.} \end{cases} \quad (12)$$

assuma que o valor do parâmetro θ é desconhecido ($\theta > 0$).
Mostraremos que $T = \prod_{i=1}^n X_i$ é uma estatística suficiente para θ .

Exemplo: Amostragem de uma Distribuição contínua

Para $0 < x_i < 1$ ($i = 1, \dots, n$) a f.d.p. conjunta $f_n(\mathbf{x}|\theta)$ de X_1, \dots, X_n é:

$$f_n(\mathbf{x}|\theta) = \theta^n \left(\prod_{i=1}^n x_i \right)^{\theta-1} \quad (13)$$

Se, pelo menos um valor de x_i estiver fora do intervalo $0 < x_i < 1$, então $f_n(\mathbf{x}|\theta) = 0$ para cada $\theta \in \Omega$. Observamos que o lado direito da equação 13 depende de \mathbf{x} através do valor do produto $\prod_{i=1}^n x_i$. Portanto, se considerarmos $u(\mathbf{x}) = 1$ e $r(\mathbf{x}) = \prod_{i=1}^n x_i$, então $f_n(\mathbf{x}|\theta)$ pode ser considerada fatorada. Segue-se então que a estatística $T = \prod_{i=1}^n X_i$ é suficiente para θ .

Exemplo: Amostragem de uma Normal

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição Normal com média desconhecido μ ($-\infty < \theta < \infty$) e variância σ^2 conhecida. Mostramos que $T = \sum_{i=1}^n X_i$ é uma estatística suficiente para μ .

Para $-\infty < x_i < \infty$ ($i = 1, \dots, n$) a f.d.p.conjunta de X_1, \dots, X_n é

$$f_n(\mathbf{x}|\mu) = \prod_{i=1}^n \frac{1}{(2\pi)^{1/2}\sigma} \exp\left[-\frac{(x_i - \mu)^2}{2\sigma^2}\right] \quad (14)$$

que pode ser rescrita como

$$f_n(\mathbf{x}|\mu) = \frac{1}{(2\pi)^{n/2}\sigma^n} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2\right) \exp\left(\frac{\mu}{\sigma^2} \sum_{i=1}^n x_i - \frac{n\mu^2}{2\sigma^2}\right) \quad (15)$$

Exemplo: Amostragem de uma Normal

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição Normal com média desconhecido μ ($-\infty < \theta < \infty$) e variância σ^2 conhecida. Mostramos que $T = \sum_{i=1}^n X_i$ é uma estatística suficiente para μ .

Para $-\infty < x_i < \infty$ ($i = 1, \dots, n$) a f.d.p.conjunta de X_1, \dots, X_n é

$$f_n(\mathbf{x}|\mu) = \prod_{i=1}^n \frac{1}{(2\pi)^{1/2}\sigma} \exp\left[-\frac{(x_i - \mu)^2}{2\sigma^2}\right] \quad (14)$$

que pode ser rescrita como

$$f_n(\mathbf{x}|\mu) = \frac{1}{(2\pi)^{n/2}\sigma^n} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2\right) \exp\left(\frac{\mu}{\sigma^2} \sum_{i=1}^n x_i - \frac{n\mu^2}{2\sigma^2}\right) \quad (15)$$

Exemplo: Amostragem de uma Normal

Suponha que as v.a. X_1, \dots, X_n formam uma a.a. de uma distribuição Normal com média desconhecido μ ($-\infty < \theta < \infty$) e variância σ^2 conhecida. Mostramos que $T = \sum_{i=1}^n X_i$ é uma estatística suficiente para μ .

Para $-\infty < x_i < \infty$ ($i = 1, \dots, n$) a f.d.p.conjunta de X_1, \dots, X_n é

$$f_n(\mathbf{x}|\mu) = \prod_{i=1}^n \frac{1}{(2\pi)^{1/2}\sigma} \exp\left[-\frac{(x_i - \mu)^2}{2\sigma^2}\right] \quad (14)$$

que pode ser rescrita como

$$f_n(\mathbf{x}|\mu) = \frac{1}{(2\pi)^{n/2}\sigma^n} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2\right) \exp\left(\frac{\mu}{\sigma^2} \sum_{i=1}^n x_i - \frac{n\mu^2}{2\sigma^2}\right) \quad (15)$$

Exemplo: Amostragem de uma Normal

pode se notar que $f_n(\mathbf{x}|\mu)$ pode ser expressado como o produto de uma função que não depende de μ e uma função que depende de \mathbf{x} através do valor de $\sum_{i=1}^n x_i$. Portanto, pelo critério de fatorização, $T = \sum_{i=1}^n nX_i$ é uma estatística suficiente para μ .

Desde que $T = \sum_{i=1}^n nX_i = n\bar{x}_n$ podemos estabelecer de forma equivalente, que fator final da equação 15 depende de x_1, \dots, x_n através do valor de \bar{x}_n , o que implica que $T = \bar{X}_n$ é uma estatística suficiente para μ .

Exemplo: Amostragem de uma Normal

pode se notar que $f_n(\mathbf{x}|\mu)$ pode ser expressado como o produto de uma função que não depende de μ e uma função que depende de \mathbf{x} através do valor de $\sum_{i=1}^n x_i$. Portanto, pelo critério de fatorização, $T = \sum_{i=1}^n nX_i$ é uma estatística suficiente para μ .

Desde que $T = \sum_{i=1}^n nX_i = n\bar{x}_n$ podemos estabelecer de forma equivalente, que fator final da equação 15 depende de x_1, \dots, x_n através do valor de \bar{x}_n , o que implica que $T = \bar{X}_n$ é uma estatística suficiente para μ .

Outline

1 Relembrando Amostras Aleatórias

- Definição de a.a.
- Exemplos de a.a.

2 Estatísticas Suficientes

- Estatísticas Suficientes
- Limitações no uso de estatísticas suficientes
- Limitações no uso de estatísticas suficientes

3 Estimadores Não Viesados

- Estimadores Não Viesados

Limitações no uso de Estatísticas Suficientes

A existência e a forma da estatística suficiente em um determinado problema depende de *maneira crítica* da forma da função assumida pela f.d.p. ou f.p. Uma estatística que é suficiente quando a f.d.p. é $f(x|\theta)$ pode não ser suficiente quando é assumido que a f.d.p. é $g(x|\theta)$, mesmo que $g(x|\theta)$ possa ser similar a $f(x|\theta)$ para cada valor de $\theta \in \Omega$.

Limitações no uso de estatísticas suficientes

Suponha que um pesquisador está em dúvida quanto à forma exata da f.d.p. em um problema específico, mas assume por conveniência que a f.d.p é $f(x|\theta)$, suponha também que a estatística T é suficiente sob essa suposição. Por causa da incerteza do pesquisador quanto à forma exata da f.d.p. ele desejaria usar um estimador de θ que "funciona" razoavelmente bem para uma ampla variedade de f.d.p's., mesmo que o estimador selecionado não apresente o requerimento que deveria depender nas observações somente através da estatística T .

Um estimador que "funciona" bem para uma ampla variedade de possíveis f.d.p's., mesmo que não seja necessariamente o melhor estimador disponível para qualquer particular família de f.d.p's. é chamado de *estimador robusto*.

Limitações no uso de estatísticas suficientes

Suponha que um pesquisador está em dúvida quanto à forma exata da f.d.p. em um problema específico, mas assume por conveniência que a f.d.p é $f(x|\theta)$, suponha também que a estatística T é suficiente sob essa suposição. Por causa da incerteza do pesquisador quanto à forma exata da f.d.p. ele desejaria usar um estimador de θ que "funciona" razoavelmente bem para uma ampla variedade de f.d.p's., mesmo que o estimador selecionado não apresente o requerimento que deveria depender nas observações somente através da estatística T .

Um estimador que "funciona" bem para uma ampla variedade de possíveis f.d.p's., mesmo que não seja necessariamente o melhor estimador disponível para qualquer particular família de f.d.p's. é chamado de *estimador robusto*.

Outline

1 Relembrando Amostras Aleatórias

- Definição de a.a.
- Exemplos de a.a.

2 Estatísticas Suficientes

- Estatísticas Suficientes
- Limitações no uso de estatísticas suficientes
- Limitações no uso de estatísticas suficientes

3 Estimadores Não Viesados

- Estimadores Não Viesados

Definição

Seja X_1, \dots, X_n uma a.a de uma distribuição com f.d.p ou f.p $f(x|\theta)$, onde $\theta \in \Omega$ é desconhecido. Neste tipo de problemas, é desejável usar um estimador $\delta(X_1, \dots, X_n)$ que, com alta probabilidade, seja próximo ao valor de θ , i.e, um estimador δ cujo valor mude com o valor de θ , de tal forma que sem interesse qual seja o valor verdadeiro de θ , a distribuição de probabilidade de δ está concentrado ao redor deste valor.

Definição

Um estimador $\delta(X_1, \dots, X_n)$ é um estimador não viesado do parâmetro θ se $E_\theta[\delta(X_1, \dots, X_n)] = \theta$, para cada possível valor de θ .

Em outras palavras, um estimador de um parâmetro θ é não viesado se sua esperança é igual ao valor desconhecido do verdadeiro valor de θ .

Exemplo

\bar{X}_n é um estimador não viesado da média desconhecida θ de uma normal, pois $E_\theta[\bar{X}_n] = \theta$ para $-\infty < \theta < \infty$.

Se X_1, \dots, X_n forma uma a.a. de uma distribuição arbitrária, para a qual a média μ é desconhecida, a média amostral sempre será um estimador não viesado de μ pois é sempre verdade que $E(\bar{X}_n) = \mu$.

Exemplo

\bar{X}_n é um estimador não viesado da média desconhecida θ de uma normal, pois $E_\theta[\bar{X}_n] = \theta$ para $-\infty < \theta < \infty$.

Se X_1, \dots, X_n forma uma a.a. de uma distribuição arbitrária, para a qual a média μ é desconhecida, a média amostral sempre será um estimador não viesado de μ pois é sempre verdade que $E(\bar{X}_n) = \mu$.

Exemplo

Se definirmos

$$S_0^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \quad (16)$$

para tentar demonstrar se é ou não um estimador não viesado de σ^2 , então usaremos a identidades:

$$\sum_{i=1}^n (X_i - \mu)^2 = \sum_{i=1}^n (X_i - \bar{X}_n)^2 + n(\bar{X}_n - \mu)^2 \quad (17)$$

então segue que

$$E[S_0^2] = E\left[\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2\right] \quad (18)$$

$$= E\left[\frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2\right] - E[(\bar{X}_n - \mu)^2] \quad (19)$$

Exemplo

Como cada observação X_i tem média μ e variância σ^2 , então:
 $E[(X_i - \mu)^2] = \sigma^2$ para $i = 1, \dots, n$. Desta forma:

$$E\left[\frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2\right] = \frac{1}{n} \sum_{i=1}^n E[(X_i - \mu)^2] = \frac{1}{n} n \sigma^2 = \sigma^2 \quad (20)$$

Como \bar{X}_n tem média μ e variância σ^2/n

$$E[(\bar{X}_n - \mu)^2] = \text{var}(\bar{X}_n) = \sigma^2/n \quad (21)$$

Segue-se então que

$$E(S_0^2) = \sigma^2 - \frac{1}{n} \sigma^2 = \frac{n-1}{n} \sigma^2 \quad (22)$$

Exemplo

O estimador não viesado de σ^2 será então:

$$s_1^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$