

# Inferência Estatística

## Introdução

E.F.T<sup>1</sup>

<sup>1</sup>EACH-USP  
Universidade de São Paulo

ACH2053

# Outline

- 1 Introdução à Inferência Estatística
  - Conceitos Gerais de Inferência Estatística
  - Distribuições a priori
  - Distribuições a posteriori
  - A função de Verossimilhança
  - Observações Sequenciais
- 2 Distribuições Conjugadas
  - Distribuições Conjugadas

# Outline

- 1 **Introdução à Inferência Estatística**
  - **Conceitos Gerais de Inferência Estatística**
  - Distribuições a priori
  - Distribuições a posteriori
  - A função de Verossimilhança
  - Observações Sequenciais
- 2 **Distribuições Conjugadas**
  - Distribuições Conjugadas

# Natureza da Inferência Estatística

## Qual a principal utilidade

Um problema de inferência estatística é um problema no qual dados que tem sido gerados de acordo com alguma distribuição de probabilidade desconhecida devem ser analisados e algum tipo de inferência sobre a distribuição desconhecida deve ser feita.

- Inferência sobre a `distribuição` .
- Inferência sobre os parâmetros da distribuição (se for conhecida a distribuição).

# Parâmetros

## Definição de parâmetro

Em um problema de Inferência Estatística, qualquer característica da distribuição que gerou os dados experimentais que tem um valor desconhecido (como a média  $\mu$  ou desvio padrão  $\sigma$ ) é chamado de parâmetro da distribuição. O conjunto  $\Omega$  de todos os possíveis valores de um parâmetro  $\theta$  ou de vetor de parâmetros  $(\theta_1, \dots, \theta_k)$  é chamado de espaço paramétrico. Notações ...

- Parâmetros
  - $\theta$
  - $(\theta_1, \dots, \theta_n)$  vetor de parâmetros
- Espaço paramétrico:
  - $\Omega$

# Parâmetros

## Definição de parâmetro

Em um problema de Inferência Estatística, qualquer característica da distribuição que gerou os dados experimentais que tem um valor desconhecido (como a média  $\mu$  ou desvio padrão  $\sigma$  é chamado de parâmetro da distribuição. O conjunto  $\Omega$  de todos os possíveis valores de um parâmetro  $\theta$  ou de vetor de parâmetros  $(\theta_1, \dots, \theta_k)$  é chamado de espaço paramétrico. Notações ...

- Parâmetros
  - $\theta$
  - $(\theta_1, \dots, \theta_n)$  vetor de parâmetros
- Espaço paramétrico:
  - $\Omega$ .

# Parâmetros

## Definição de parâmetro

Em um problema de Inferência Estatística, qualquer característica da distribuição que gerou os dados experimentais que tem um valor desconhecido (como a média  $\mu$  ou desvio padrão  $\sigma$  é chamado de parâmetro da distribuição. O conjunto  $\Omega$  de todos os possíveis valores de um parâmetro  $\theta$  ou de vetor de parâmetros  $(\theta_1, \dots, \theta_k)$  é chamado de espaço paramétrico. Notações ...

- Parâmetros
  - $\theta$
  - $(\theta_1, \dots, \theta_n)$  vetor de parâmetros
- Espaço paramétrico:
  - $\Omega$ .

# Outline

- 1 **Introdução à Inferência Estatística**
  - Conceitos Gerais de Inferência Estatística
  - **Distribuições a priori**
  - Distribuições a posteriori
  - A função de Verossimilhança
  - Observações Sequenciais
  
- 2 **Distribuições Conjugadas**
  - Distribuições Conjugadas



# Distribuições a priori

Suponha um problema de inferência estatística em que as observações são tomadas de uma distribuição  $f(x|\theta)$ , onde  $\theta$  é um parâmetro com valor desconhecido. Assumimos que o valor de  $\theta$  deve pertencer a um espaço paramétrico especificado  $\Omega$ . O problema de I.E. consiste em determinar na base das observações de  $f(x|\theta)$  em que lugar de  $\Omega$  se encontra atualmente  $\theta$ .

# Distribuições a priori

Em muitos problemas, antes da  $f(x|\theta)$  gerar as observações, o analista será capaz de sumarizar (experiência anterior) sua informação prévia sobre em que lugar de  $\Omega$  se encontra  $\theta$  com maior probabilidade, sendo possível construir uma distribuição de probabilidade para  $\theta$  no conjunto  $\Omega$ . Esta distribuição é chamada de distribuição a priori de  $\theta$ .

## Distrib. a priori discretas e contínuas

Se o parâmetro  $\theta$  tomar um número de valores finito ou no máximo uma sequência contável infinita, então  $\xi(\theta)$  será uma f.p. a priori. Se  $\theta$  tomar valores num intervalo da reta, então  $\xi(\theta)$  será uma f.d.p a priori de  $\theta$ .

## Exemplo: Moeda honesta ou de duas caras

Seja  $\theta$  a probabilidade de obter cara quando certa moeda é lançada. Suponha que a moeda pode ser honesta ou ter duas caras. Portanto, os únicos valores possíveis para  $\theta$  são  $\theta = 1/2$  ou  $\theta = 1$ . Se a probabilidade a priori que a moeda é honesta é  $p$ , então a f.p a priori de  $\theta$  é  $\xi(1/2) = p$  e  $\xi(1) = 1 - p$ .

## Exemplo: Exemplo: Proporção de itens defeituosos

Suponha que a proporção  $\theta$  de itens defeituosos em um lote grande é desconhecido, e que a fdp a priori atribuída a  $\theta$  é uma distribuição uniforme em  $(0,1)$ . Então a fdp a priori de  $\theta$  é :

$$\xi(\theta) = \begin{cases} 1 & \text{para } 0 < \theta < 1. \\ 0 & \text{c.c.} \end{cases}$$

# Outline

- 1 **Introdução à Inferência Estatística**
  - Conceitos Gerais de Inferência Estatística
  - Distribuições a priori
  - **Distribuições a posteriori**
  - A função de Verossimilhança
  - Observações Sequenciais
  
- 2 **Distribuições Conjugadas**
  - Distribuições Conjugadas

## Distribuições a posteriori

Suponha que  $n$  v.a.  $X_1, X_2, \dots, X_n$  formam uma a.a. de uma distribuição com  $f(x|\theta)$ . Suponha também que o valor do parâmetro  $\theta$  é desconhecido e que a distribuição a priori de  $\theta$  é  $\xi(\theta)$ . Assumimos que o espaço paramétrico é  $\Omega$ .

Como as v.a.  $X_1, X_2, \dots, X_n$  formam uma a.a. da distribuição com  $f(x|\theta)$ , então a distribuição conjunta será dada por:

$$f_n(x_1, x_2, \dots, x_n|\theta) = f(x_1|\theta) \dots f(x_n|\theta) \quad (1)$$

## Distribuições a posteriori

Se denotarmos  $\mathbf{x} = (x_1, x_2, \dots, x_n)$ , a equação 1 pode ser escrita como  $f_n(\mathbf{x}|\theta)$ .

O parâmetro  $\theta \sim \xi(\theta)$ , e a função de probabilidade(densidade)  $f_n(\mathbf{x}|\theta)$ , dever então ser a distribuição condicional de  $X_1, X_2, \dots, X_n$  para um dado valor  $\theta$ . Multiplicando  $f_n(\mathbf{x}|\theta)$  e  $\xi(\theta)$  obtemos a conjunta  $n + 1$ -dimensional de  $X_1, X_2, \dots, X_n$  e  $\theta$ , na forma  $f_n(\mathbf{x}|\theta)\xi(\theta)$ . Assim, a marginal de  $X_1, X_2, \dots, X_n$  pode ser obtido integrando a conjunta sobre todos os valores de  $\theta$ :

$$g_n(\mathbf{x}) = \int_{\Omega} f_n(\mathbf{x}|\theta)\xi(\theta)d(\theta) \quad (2)$$



## Distribuições a posteriori

Também, a distribuição condicional de  $\theta$  dado que  $X_1 = x_1, \dots, X_n = x_n$  que denotaremos por  $\xi(\theta|\mathbf{x})$ , deve ser igual à conjunta de  $X_1, X_2, \dots, X_n$  e  $\theta$  dividida pela marginal de  $X_1, X_2, \dots, X_n$ . Assim, temos:

$$\xi(\theta|\mathbf{x}) = \frac{f_n(\mathbf{x}|\theta)\xi(\theta)}{g_n(\mathbf{x})}, \quad \text{para } \theta \in \Omega \quad (3)$$

A equação 3 é chamada a distribuição a posteriori de  $\theta$  pois é a distribuição de  $\theta$  após os valores de  $X_1, X_2, \dots, X_n$  terem sido observados.

# Distribuições a posteriori

Podemos dizer que a priori  $\xi(\theta)$  representa a verossimilhança relativa que o valor verdadeiro de  $\theta$  está em alguma região de  $\Omega$  antes de que os valores de  $X_1, X_2, \dots, X_n$  sejam observados, e que a posteriori  $\xi(\theta|\mathbf{x})$  representa esta verossimilhança relativa após os valores  $X_1 = x_1, \dots, X_n = x_n$  terem sido observados.

# Outline

- 1 **Introdução à Inferência Estatística**
  - Conceitos Gerais de Inferência Estatística
  - Distribuições a priori
  - Distribuições a posteriori
  - **A função de Verossimilhança**
  - Observações Sequenciais
  
- 2 **Distribuições Conjugadas**
  - Distribuições Conjugadas

## A função de Verossimilhança

O denominador do lado direito da equação 3, é simplesmente a integral do numerador sobre todos os possíveis valores de  $\theta$ . Este valor, depende então dos valores observados  $x_1, \dots, x_n$  e não de  $\theta$  e pode ser tratado como uma constante quando o lado direito da equação 3 é uma distribuição em  $\theta$ . Temos portanto a relação:

$$\xi(\theta|\mathbf{x}) \propto f_n(\mathbf{x}|\theta) \xi(\theta) \quad (4)$$

Quando a conjunta  $f_n(\mathbf{x}|\theta)$  das observações numa a.a. é considerada como uma função de  $\theta$  para valores dados de  $x_1, \dots, x_n$  é chamado de *função de verossimilhança*. Então o produto na equação 4 estabelece que a posteriori é proporcional ao produto da função de verossimilhança e a priori de  $\theta$ .

## Exemplo: proporção de itens defeituosos

Suponha que a proporção  $\theta$  de itens defeituosos de um lote (grande) de peças é desconhecida e que a priori de  $\theta$  é uma uniforme no intervalo  $(0, 1)$ . Suponha também que uma a.a. de  $n$  itens é tomado do lote, e para  $i = 1, \dots, n$  seja  $X_i = 1$  se o  $i$ -ésimo item selecionado é defeituoso e  $X_i = 0$  caso contrário. Então,  $X_1, X_2, \dots, X_n$  forma  $n$  ensaios de Bernoulli com parâmetro  $\theta$ . Determine a posteriori de  $\theta$ . Podemos ver que a distribuição para cada observação  $X_i$  é:

$$f(x|\theta) = \begin{cases} \theta^x(1 - \theta)^{1-x} & \text{para } x = 0, 1 \\ 0 & \text{c.c} \end{cases} \quad (5)$$

## Exemplo: proporção de itens defeituosos

Seja  $y = \sum_{i=1}^n x_i$ , então a densidade conjunta de  $X_1, X_2, \dots, X_n$  pode ser escrita para  $x_i = 0$  ou  $x_i = 1$ :

$$f_n(\mathbf{x}|\theta) = \theta^y (1 - \theta)^{n-y}$$

como a priori  $x_i(\theta)$  é dado por

$$\xi(\theta) = \begin{cases} 1 & \text{para } 0 < \theta < 1. \\ 0 & \text{c.c.} \end{cases}$$

então, para  $0 < \theta < 1$ :

$$f_n(\mathbf{x}|\theta) = \theta^y (1 - \theta)^{n-y}$$

vemos que exceto uma constante, a posteriori tem a forma de uma distribuição Beta com parâmetros  $\alpha = y + 1$  e  $\beta = n - y + 1$ .

# Outline

- 1 Introdução à Inferência Estatística
  - Conceitos Gerais de Inferência Estatística
  - Distribuições a priori
  - Distribuições a posteriori
  - A função de Verossimilhança
  - Observações Sequenciais
- 2 Distribuições Conjugadas
  - Distribuições Conjugadas

# Observações Sequenciais

Em muitos experimentos, as observações  $X_1, X_2, \dots, X_n$  que formam uma a.a. devem ser obtidos sequencialmente, isto é, um por vez. Em tais experimentos, o valor de  $X_1$  é observado primeiro, depois é observado  $X_2$ , e assim sucessivamente. Suponha que a priori de  $\theta$  é  $\xi(\theta)$ . Depois que o valor de  $X_1$  for observado, a posteriori  $\xi(\theta|x_1)$  pode ser calculado segundo a relação:

$$\xi(\theta|x_1) \propto f(x_1|\theta)\xi(\theta)$$



## Observações Sequenciais

Esta posteriori servirá como priori de  $\theta$  quando o valor de  $X_2$  seja calculado. Assim, após o valor  $x_2$  de  $X_2$  for observado, a posteriori  $\xi(\theta|x_1, x_2)$  pode ser calculado da relação:

$$\xi(\theta|x_1, x_2) \propto f(x_2|\theta)\xi(\theta|x_1)$$

Se continuarmos neste cálculo, teremos a seguinte relação:

$$\xi(\theta|\mathbf{x}) \propto f(x_n|\theta)\xi(\theta|x_1, \dots, x_{n-1})$$

# Outline

- 1 Introdução à Inferência Estatística
  - Conceitos Gerais de Inferência Estatística
  - Distribuições a priori
  - Distribuições a posteriori
  - A função de Verossimilhança
  - Observações Sequenciais
- 2 Distribuições Conjugadas
  - Distribuições Conjugadas

# Distribuições conjugadas

Algumas distribuições a priori são particularmente convenientes de serem usadas com amostras de outras distribuições.

- Amostragem de uma distribuição de Bernoulli
  - $X_1, X_2, \dots, X_n$  forma uma a.a. de uma Bernoulli com
  - $\theta$  desconhecido ( $0 < \theta < 1$ )
  - a priori de  $\theta$  é uma Beta com parâmetros  $\alpha > 0$  e  $\beta > 0$
  - a posteriori de  $\theta$  dado que  $X_i = x_i$  ( $i = 1, \dots, n$ ) será uma Beta com parâmetros  $\alpha + \sum_{i=1}^n x_i$  e  $\beta + n - \sum_{i=1}^n x_i$

# Distribuições conjugadas

Algumas distribuições a priori são particularmente convenientes de serem usadas com amostras de outras distribuições.

- Amostragem de uma distribuição de Bernoulli
  - $X_1, X_2, \dots, X_n$  forma uma a.a. de uma Bernoulli com
  - $\theta$  desconhecido ( $0 < \theta < 1$ )
  - a priori de  $\theta$  é uma Beta com parâmetros  $\alpha > 0$  e  $\beta > 0$
  - a posteriori de  $\theta$  dado que  $X_i = x_i$  ( $i = 1, \dots, n$ ) será uma Beta com parâmetros  $\alpha + \sum_{i=1}^n x_i$  e  $\beta + n - \sum_{i=1}^n x_i$

# Distribuições conjugadas

Algumas distribuições a priori são particularmente convenientes de serem usadas com amostras de outras distribuições.

- Amostragem de uma distribuição de Bernoulli
  - $X_1, X_2, \dots, X_n$  forma uma a.a. de uma Bernoulli com
  - $\theta$  desconhecido ( $0 < \theta < 1$ )
  - a priori de  $\theta$  é uma Beta com parâmetros  $\alpha > 0$  e  $\beta > 0$
  - a posteriori de  $\theta$  dado que  $X_i = x_i$  ( $i = 1, \dots, n$ ) será uma Beta com parâmetros  $\alpha + \sum_{i=1}^n x_i$  e  $\beta + n - \sum_{i=1}^n x_i$

# Distribuições conjugadas

Algumas distribuições a priori são particularmente convenientes de serem usadas com amostras de outras distribuições.

- Amostragem de uma distribuição de Bernoulli
  - $X_1, X_2, \dots, X_n$  forma uma a.a. de uma Bernoulli com
  - $\theta$  desconhecido ( $0 < \theta < 1$ )
  - a priori de  $\theta$  é uma Beta com parâmetros  $\alpha > 0$  e  $\beta > 0$
  - a posteriori de  $\theta$  dado que  $X_i = x_i$  ( $i = 1, \dots, n$ ) será uma Beta com parâmetros  $\alpha + \sum_{i=1}^n x_i$  e  $\beta + n - \sum_{i=1}^n x_i$

# Distribuições conjugadas

- Amostragem de uma distribuição de Poisson
  - $X_1, X_2, \dots, X_n$  forma uma a.a. de uma Poisson com
  - $\theta$  desconhecido ( $0 < \theta$ )
  - a priori de  $\theta$  é uma Gamma com parâmetros  $\alpha > 0$  e  $\beta > 0$
  - a posteriori de  $\theta$  dado que  $X_i = x_i$  ( $i = 1, \dots, n$ ) será uma Beta com parâmetros  $\alpha + \sum_{i=1}^n x_i$  e  $\beta + n$

# Distribuições conjugadas

- Amostragem de uma distribuição de Poisson
  - $X_1, X_2, \dots, X_n$  forma uma a.a. de uma Poisson com
  - $\theta$  desconhecido ( $0 < \theta$ )
  - a priori de  $\theta$  é uma Gamma com parâmetros  $\alpha > 0$  e  $\beta > 0$
  - a posteriori de  $\theta$  dado que  $X_i = x_i$  ( $i = 1, \dots, n$ ) será uma Beta com parâmetros  $\alpha + \sum_{i=1}^n x_i$  e  $\beta + n$



# Distribuições conjugadas

- Amostragem de uma distribuição de Poisson
  - $X_1, X_2, \dots, X_n$  forma uma a.a. de uma Poisson com
  - $\theta$  desconhecido ( $0 < \theta$ )
  - a priori de  $\theta$  é uma Gamma com parâmetros  $\alpha > 0$  e  $\beta > 0$
  - a posteriori de  $\theta$  dado que  $X_i = x_i$  ( $i = 1, \dots, n$ ) será uma Beta com parâmetros  $\alpha + \sum_{i=1}^n x_i$  e  $\beta + n$

# Distribuições conjugadas

- Amostragem de uma distribuição de Poisson
  - $X_1, X_2, \dots, X_n$  forma uma a.a. de uma Poisson com
  - $\theta$  desconhecido ( $0 < \theta$ )
  - a priori de  $\theta$  é uma Gamma com parâmetros  $\alpha > 0$  e  $\beta > 0$
  - a posteriori de  $\theta$  dado que  $X_i = x_i$  ( $i = 1, \dots, n$ ) será uma Beta com parâmetros  $\alpha + \sum_{i=1}^n x_i$  e  $\beta + n$

# Distribuições conjugadas

- Amostragem de uma distribuição Normal
  - $X_1, X_2, \dots, X_n$  forma uma a.a. de uma Normal com
  - média  $\theta$  desconhecido ( $-\infty < \theta < \infty$ ),  $\sigma^2$  conhecido ( $\sigma^2 > 0$ )
  - a priori de  $\theta$  é uma normal com média  $\mu$  e variância  $\nu^2$
  - a posteriori de  $\theta$  dado que  $X_i = x_i$  ( $i = 1, \dots, n$ ) será uma normal com parâmetros  $\mu_1$  e variância  $\nu_1^2$ :

$$\mu_1 = \frac{\sigma^2 \mu + n \nu^2 \bar{x}_n}{\sigma^2 + n \nu^2}$$

$$\nu_1^2 = \frac{\sigma^2 \nu^2}{\sigma^2 + n \nu^2}$$

# Distribuições conjugadas

- Amostragem de uma distribuição Normal
  - $X_1, X_2, \dots, X_n$  forma uma a.a. de uma Normal com
  - média  $\theta$  desconhecido ( $-\infty < \theta < \infty$ ),  $\sigma^2$  conhecido ( $\sigma^2 > 0$ )
  - a priori de  $\theta$  é uma normal com média  $\mu$  e variância  $\nu^2$
  - a posteriori de  $\theta$  dado que  $X_i = x_i$  ( $i = 1, \dots, n$ ) será uma normal com parâmetros  $\mu_1$  e variância  $\nu_1^2$ :

$$\mu_1 = \frac{\sigma^2 \mu + n \nu^2 \bar{x}_n}{\sigma^2 + n \nu^2}$$

$$\nu_1^2 = \frac{\sigma^2 \nu^2}{\sigma^2 + n \nu^2}$$

# Distribuições conjugadas

- Amostragem de uma distribuição Normal
  - $X_1, X_2, \dots, X_n$  forma uma a.a. de uma Normal com
  - média  $\theta$  desconhecido ( $-\infty < \theta < \infty$ ),  $\sigma^2$  conhecido ( $\sigma^2 > 0$ )
  - a priori de  $\theta$  é uma normal com média  $\mu$  e variância  $\nu^2$
  - a posteriori de  $\theta$  dado que  $X_i = x_i$  ( $i = 1, \dots, n$ ) será uma normal com parâmetros  $\mu_1$  e variância  $\nu_1^2$ :

$$\mu_1 = \frac{\sigma^2 \mu + n \nu^2 \bar{x}_n}{\sigma^2 + n \nu^2}$$

$$\nu_1^2 = \frac{\sigma^2 \nu^2}{\sigma^2 + n \nu^2}$$

# Distribuições conjugadas

- Amostragem de uma distribuição Normal
  - $X_1, X_2, \dots, X_n$  forma uma a.a. de uma Normal com
  - média  $\theta$  desconhecido ( $-\infty < \theta < \infty$ ),  $\sigma^2$  conhecido ( $\sigma^2 > 0$ )
  - a priori de  $\theta$  é uma normal com média  $\mu$  e variância  $\nu^2$
  - a posteriori de  $\theta$  dado que  $X_i = x_i$  ( $i = 1, \dots, n$ ) será uma normal com parâmetros  $\mu_1$  e variância  $\nu_1^2$ :

$$\mu_1 = \frac{\sigma^2 \mu + n \nu^2 \bar{x}_n}{\sigma^2 + n \nu^2}$$

$$\nu_1^2 = \frac{\sigma^2 \nu^2}{\sigma^2 + n \nu^2}$$

# Distribuições conjugadas

- Amostragem de uma distribuição exponencial
  - $X_1, X_2, \dots, X_n$  forma uma a.a. de uma exponencial com
  - $\theta$  desconhecido ( $0 < \theta$ )
  - a priori de  $\theta$  é uma Gamma com parâmetros  $\alpha > 0$  e  $\beta > 0$
  - a posteriori de  $\theta$  dado que  $X_i = x_i$  ( $i = 1, \dots, n$ ) será uma Gamma com parâmetros  $\alpha + n$  e  $\beta + \sum_{i=1}^n x_i$

# Distribuições conjugadas

- Amostragem de uma distribuição exponencial
  - $X_1, X_2, \dots, X_n$  forma uma a.a. de uma exponencial com
  - $\theta$  desconhecido ( $0 < \theta$ )
  - a priori de  $\theta$  é uma Gamma com parâmetros  $\alpha > 0$  e  $\beta > 0$
  - a posteriori de  $\theta$  dado que  $X_i = x_i$  ( $i = 1, \dots, n$ ) será uma Gamma com parâmetros  $\alpha + n$  e  $\beta + \sum_{i=1}^n x_i$



# Distribuições conjugadas

- Amostragem de uma distribuição exponencial
  - $X_1, X_2, \dots, X_n$  forma uma a.a. de uma exponencial com
  - $\theta$  desconhecido ( $0 < \theta$ )
  - a priori de  $\theta$  é uma Gamma com parâmetros  $\alpha > 0$  e  $\beta > 0$
  - a posteriori de  $\theta$  dado que  $X_i = x_i$  ( $i = 1, \dots, n$ ) será uma Gamma com parâmetros  $\alpha + n$  e  $\beta + \sum_{i=1}^n x_i$

# Distribuições conjugadas

- Amostragem de uma distribuição exponencial
  - $X_1, X_2, \dots, X_n$  forma uma a.a. de uma exponencial com
  - $\theta$  desconhecido ( $0 < \theta$ )
  - a priori de  $\theta$  é uma Gamma com parâmetros  $\alpha > 0$  e  $\beta > 0$
  - a posteriori de  $\theta$  dado que  $X_i = x_i$  ( $i = 1, \dots, n$ ) será uma Gamma com parâmetros  $\alpha + n$  e  $\beta + \sum_{i=1}^n x_i$