

# Inferência Estatística

## Introdução

E.F.T<sup>1</sup>

<sup>1</sup>EACH-USP  
Universidade de São Paulo

ACH2053

# Outline

- 1 Estimadores Máxima Verossimilhança
  - Estimadores de Máxima Verossimilhança
  - Casos dignos de nota
  - Propriedades dos Estimadores de Máxima Verossimilhança

# Outline

- 1 Estimadores Máxima Verossimilhança
  - Estimadores de Máxima Verossimilhança
  - Casos dignos de nota
  - Propriedades dos Estimadores de Máxima Verossimilhança

# Limitações dos Estimadores de Bayes

para aplicar a teoria dos estimadores Bayesianos, é necessário:

- especificar a função de perda,
- determinar uma priori para o parâmetro.

ou também,  $\theta$  pode ser um vetor, para a qual haveria de se especificar uma distribuição a priori multivariada.

# Limitações dos Estimadores de Bayes

para aplicar a teoria dos estimadores Bayesianos, é necessário:

- especificar a função de perda,
- determinar uma priori para o parâmetro.

ou também,  $\theta$  pode ser um vetor, para a qual haveria de se especificar uma distribuição a priori multivariada.

# Limitações dos Estimadores de Bayes

para aplicar a teoria dos estimadores Bayesianos, é necessário:

- especificar a função de perda,
- determinar uma priori para o parâmetro.

ou também,  $\theta$  pode ser um vetor, para a qual haveria de se especificar uma distribuição a priori multivariada.

# Definição de um Estimador de Máxima Verossimilhança

Suponha que as v.a.  $X_1, \dots, X_n$  formam uma a.a. cuja distribuição é  $f(x|\theta)$ , onde  $\theta$  é desconhecido e pertence ao espaço paramétrico  $\Omega$ . Para qualquer vetor observado  $\mathbf{x} = (x_1, \dots, x_n)$  na amostra, o valor da conjunta será denotados por  $f_n(\mathbf{x}|\theta)$ .

Quando  $f_n(\mathbf{x}|\theta)$  é considerado uma função de  $\theta$  para um vetor  $\mathbf{x}$  dado, é chamado de *função de verossimilhança*.

# Definição de um Estimador de Máxima Verossimilhança

Suponha que as v.a.  $X_1, \dots, X_n$  formam uma a.a. cuja distribuição é  $f(x|\theta)$ , onde  $\theta$  é desconhecido e pertence ao espaço paramétrico  $\Omega$ . Para qualquer vetor observado  $\mathbf{x} = (x_1, \dots, x_n)$  na amostra, o valor da conjunta será denotados por  $f_n(\mathbf{x}|\theta)$ .

Quando  $f_n(\mathbf{x}|\theta)$  é considerado uma função de  $\theta$  para um vetor  $\mathbf{x}$  dado, é chamado de *função de verossimilhança*.



# Definição de um Estimador de Máxima Verossimilhança

Suponha que as v.a.  $X_1, \dots, X_n$  formam uma a.a. cuja distribuição é  $f(x|\theta)$ , onde  $\theta$  é desconhecido e pertence ao espaço paramétrico  $\Omega$ . Para qualquer vetor observado  $\mathbf{x} = (x_1, \dots, x_n)$  na amostra, o valor da conjunta será denotados por  $f_n(\mathbf{x}|\theta)$ .

Quando  $f_n(\mathbf{x}|\theta)$  é considerado uma função de  $\theta$  para um vetor  $\mathbf{x}$  dado, é chamado de *função de verossimilhança*.

# Definição de um Estimador de Máxima Verossimilhança

Supondo que o vetor  $\mathbf{x}$  vem de uma distribuição discreta. Se uma estimativa de  $\theta$  deve ser selecionada, não considerariamos qualquer valor de  $\theta \in \Omega$  com o qual seria impossível conseguir o atual valor de  $\mathbf{x}$ .

Suponha que a probabilidade  $f_n(\mathbf{x}|\theta)$  de obter o atual vetor observado é alta para determinado valor de  $\theta = \theta_0$  e pequena para qualquer outro valor de  $\theta \in \Omega$ . Então, naturalmente estimariamos o valor de  $\theta$  como  $\theta_0$ .

# Definição de um Estimador de Máxima Verossimilhança

Supondo que o vetor  $\mathbf{x}$  vem de uma distribuição discreta. Se uma estimativa de  $\theta$  deve ser selecionada, não considerariamos qualquer valor de  $\theta \in \Omega$  com o qual seria impossível conseguir o atual valor de  $\mathbf{x}$ .

Suponha que a probabilidade  $f_n(\mathbf{x}|\theta)$  de obter o atual vetor observado é alta para determinado valor de  $\theta = \theta_0$  e pequena para qualquer outro valor de  $\theta \in \Omega$ . Então, naturalmente estimariamos o valor de  $\theta$  como  $\theta_0$ .

# Definição de um Estimador de Máxima Verossimilhança

Supondo que o vetor  $\mathbf{x}$  vem de uma distribuição discreta. Se uma estimativa de  $\theta$  deve ser selecionada, não considerariamos qualquer valor de  $\theta \in \Omega$  com o qual seria impossível conseguir o atual valor de  $\mathbf{x}$ .

Suponha que a probabilidade  $f_n(\mathbf{x}|\theta)$  de obter o atual vetor observado é alta para determinado valor de  $\theta = \theta_0$  e pequena para qualquer outro valor de  $\theta \in \Omega$ . Então, naturalmente estimariamos o valor de  $\theta$  como  $\theta_0$ .

# Definição de um Estimador de Máxima Verossimilhança

Para cada valor possível do vetor  $\mathbf{x}$ , seja  $\delta(\mathbf{x}) \in \Omega$  o valor de  $\theta \in \Omega$  para a qual a função de verossimilhança  $f_n((\mathbf{x}|\theta)$  é um máximo, e seja  $\hat{\theta} = \delta(\mathbf{X})$  o estimador de  $\theta$  definido desta forma. O estimador  $\hat{\theta}$  é chamado de *estimador de máxima verossimilhança* de  $\theta$ , ou abreviadamente EMV de  $\theta$ .

# Outline

- 1 Estimadores Máxima Verossimilhança
  - Estimadores de Máxima Verossimilhança
  - Casos dignos de nota
  - Propriedades dos Estimadores de Máxima Verossimilhança

# Exemplos de EMV

## casos de nota

- Em alguns problemas, para valores observados  $\mathbf{x}$ , um valor máximo para  $f_n(\mathbf{x}|\theta)$  pode não ser obtido para qualquer ponto  $\theta \in \Omega$ . Neste caso o EMV não existe.
- Para certos  $\mathbf{x}$  observados, o máximo para  $f_n(\mathbf{x}|\theta)$  pode ser obtido em vários pontos de  $\Omega$ , em tais casos, o EMV não é único e um destes pontos pode ser escolhido como a estimativa  $\hat{\theta}$ .
- Em outros casos, o EMV existe e é único.

# Exemplos de EMV

## casos de nota

- Em alguns problemas, para valores observados  $\mathbf{x}$ , um valor máximo para  $f_n(\mathbf{x}|\theta)$  pode não ser obtido para qualquer ponto  $\theta \in \Omega$ . Neste caso o EMV não existe.
- Para certos  $\mathbf{x}$  observados, o máximo para  $f_n(\mathbf{x}|\theta)$  pode ser obtido em vários pontos de  $\Omega$ , em tais casos, o EMV não é único e um destes pontos pode ser escolhido como a estimativa  $\hat{\theta}$ .
- Em outros casos, o EMV existe e é único.



# Exemplos de EMV

## casos de nota

- Em alguns problemas, para valores observados  $\mathbf{x}$ , um valor máximo para  $f_n(\mathbf{x}|\theta)$  pode não ser obtido para qualquer ponto  $\theta \in \Omega$ . Neste caso o EMV não existe.
- Para certos  $\mathbf{x}$  observados, o máximo para  $f_n(\mathbf{x}|\theta)$  pode ser obtido em vários pontos de  $\Omega$ , em tais casos, o EMV não é único e um destes pontos pode ser escolhido como a estimativa  $\hat{\theta}$ .
- Em outros casos, o EMV existe e é único.

# Exemplos de EMV

## Amostragem de uma Bernoulli

Suponha que  $X_1, X_2, \dots, X_n$  formam uma a.a. de uma distribuição de Bernoulli com  $\theta$  desconhecido ( $0 \leq \theta \leq 1$ ). Para valores observados  $x_1, \dots, x_n$ , onde cada  $x_i$  é 0 ou 1, a função de verossimilhança é:

$$f_n(\mathbf{x}|\theta) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} \quad (1)$$

# Exemplos de EMV

## Amostragem de uma Bernoulli

O valor de  $\theta$  que maximiza  $f_n(\mathbf{x}|\theta)$  será o mesmo que maximiza  $\log f_n(\mathbf{x}|\theta)$ . Portanto, será conveniente determinar o EMV encontrando o valor de  $\theta$  que maximiza:

$$\begin{aligned} L(\theta) &= \log f_n(\mathbf{x}|\theta) = \sum_{i=1}^n [x_i \log(\theta) + (1 - x_i) \log(1 - \theta)] \quad (2) \\ &= (\sum_{i=1}^n x_i) \log(\theta) + (n - \sum_{i=1}^n x_i) \log(1 - \theta) \end{aligned}$$

# Exemplos de EMV

## Amostragem de uma Bernoulli

Se calcularmos a derivada  $dL(\theta)/d\theta$ , e igualarmos esta derivada a 0, resolvendo a equação para  $\theta$  encontraremos que  $\theta = \bar{x}_n$ . Pode ser verificado que este valor maximiza  $L(\theta)$ , portanto, maximiza a função de verossimilhança. Segue-se que a EMV de  $\theta$  é  $\hat{\theta} = \bar{X}_n$ .

Logo, se  $X_1, X_2, \dots, X_n$  são  $n$  ensaios de Bernoulli, então o EMV de probabilidade de sucesso (desconhecida) em qualquer ensaio dado é simplesmente a proporção de sucessos observados nos  $n$  ensaios.

# Exemplos de EMV

## Amostragem de uma Bernoulli

Se calcularmos a derivada  $dL(\theta)/d\theta$ , e igualarmos esta derivada a 0, resolvendo a equação para  $\theta$  encontraremos que  $\theta = \bar{x}_n$ . Pode ser verificado que este valor maximiza  $L(\theta)$ , portanto, maximiza a função de verossimilhança. Segue-se que a EMV de  $\theta$  é  $\hat{\theta} = \bar{X}_n$ .

Logo, se  $X_1, X_2, \dots, X_n$  são  $n$  ensaios de Bernoulli, então o EMV de probabilidade de sucesso (desconhecida) em qualquer ensaio dado é simplesmente a proporção de sucessos observados nos  $n$  ensaios.

# Exemplos de EMV

## Amostragem de uma Normal (com variância conhecida)

Suponha que  $X_1, X_2, \dots, X_n$  formam uma a.a. de uma distribuição Normal com média  $\mu$  desconhecida e variância  $\sigma^2$  conhecida. Para valores observados  $x_1, \dots, x_n$ , a função de verossimilhança é:

$$f_n(\mathbf{x}|\mu) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right] \quad (3)$$

# Exemplos de EMV

## Amostragem de uma Normal (com variância conhecida)

Pode-se ver que  $f_n(\mathbf{x}|\mu)$  será maximizado pelo valor de  $\mu$  que maximiza

$$Q(\mu) = \sum_{i=1}^n (x_i - \mu)^2 = \sum_{i=1}^n x_i^2 - 2\mu \sum_{i=1}^n x_i + n\mu^2$$

Se calcularmos a derivada  $dQ(\mu)/d\mu$ , igualamos a 0 e resolvemos esta equação para  $\mu$  encontraremos que  $\mu = \bar{x}_n$ .

Segue-se então que o EMV de  $\mu$  é  $\hat{\mu} = \bar{X}_n$ .

Pode ser visto acima que o valor de  $\hat{\mu}$  não é afetado pelo valor da variância  $\sigma^2$ .

# Exemplos de EMV

## Amostragem de uma Normal (com variância conhecida)

Pode-se ver que  $f_n(\mathbf{x}|\mu)$  será maximizado pelo valor de  $\mu$  que maximiza

$$Q(\mu) = \sum_{i=1}^n (x_i - \mu)^2 = \sum_{i=1}^n x_i^2 - 2\mu \sum_{i=1}^n x_i + n\mu^2$$

Se calcularmos a derivada  $dQ(\mu)/d\mu$ , igualamos a 0 e resolvemos esta equação para  $\mu$  encontraremos que  $\mu = \bar{x}_n$ . Segue-se então que o EMV de  $\mu$  é  $\hat{\mu} = \bar{X}_n$ .

Pode ser visto acima que o valor de  $\hat{\mu}$  não é afetado pelo valor da variância  $\sigma^2$ .



# Exemplos de EMV

## Amostragem de uma Normal (com variância conhecida)

Pode-se ver que  $f_n(\mathbf{x}|\mu)$  será maximizado pelo valor de  $\mu$  que maximiza

$$Q(\mu) = \sum_{i=1}^n (x_i - \mu)^2 = \sum_{i=1}^n x_i^2 - 2\mu \sum_{i=1}^n x_i + n\mu^2$$

Se calcularmos a derivada  $dQ(\mu)/d\mu$ , igualamos a 0 e resolvemos esta equação para  $\mu$  encontraremos que  $\mu = \bar{x}_n$ .

Segue-se então que o EMV de  $\mu$  é  $\hat{\mu} = \bar{X}_n$ .

Pode ser visto acima que o valor de  $\hat{\mu}$  não é afetado pelo valor da variância  $\sigma^2$ .

# Exemplos de EMV

## Amostragem de uma Normal (com variância desconhecida)

Suponha que  $X_1, X_2, \dots, X_n$  formam uma a.a. de uma distribuição Normal com média  $\mu$  desconhecida e variância  $\sigma^2$  desconhecida. Para valores observados  $x_1, \dots, x_n$ , a função de verossimilhança é:

$$f_n(\mathbf{x}|\mu, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right] \quad (4)$$

Esta função será maximizada para possíveis valores de  $-\infty < \mu < \infty$  e  $\sigma^2 > 0$ . Em lugar de maximizar a  $f_n(\mathbf{x}|\mu, \sigma^2)$  é mais fácil maximizar  $\log f_n(\mathbf{x}|\mu, \sigma^2)$ .

# Exemplos de EMV

## Amostragem de uma Normal (com variância desconhecida)

Temos:

$$\begin{aligned} L(\mu, \sigma^2) &= \log f_n(\mathbf{x}|\mu, \sigma^2) \\ &= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \end{aligned} \quad (5)$$

Devemos encontrar os valores de  $\mu$  e de  $\sigma^2$  para os quais  $L(\mu, \sigma^2)$  é máximo encontrando os valores de  $\mu$  e de  $\sigma^2$  que satisfazem as equações:

$$\frac{\partial L(\mu, \sigma^2)}{\partial \mu} = 0 \quad (6)$$

$$\frac{\partial L(\mu, \sigma^2)}{\partial \sigma^2} = 0 \quad (7)$$

# Exemplos de EMV

## Amostragem de uma Normal (com variância desconhecida)

Da primeira equação obtemos:

$$\frac{\partial L(\mu, \sigma^2)}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = \frac{1}{\sigma^2} \left( \sum_{i=1}^n x_i - n\mu \right)$$

encontramos aqui que  $\mu = \bar{x}_i$ . Também:

$$\frac{\partial L(\mu, \sigma^2)}{\partial \sigma^2} = -\frac{n}{\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2$$

substituindo  $\mu$  por  $\bar{x}_n$  encontramos que

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_n)^2 \quad (8)$$

# Exemplos de EMV

## Amostragem de uma Normal (com variância desconhecida)

Observamos portanto que os EMV de  $\mu$  e de  $\sigma^2$  (que maximizam a função  $L(\mu, \sigma^2)$ ) são

$$\hat{\mu} = \bar{X}_n$$

e

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

# Exemplos de EMV

## Amostragem de uma Uniforme

Suponha que  $X_1, X_2, \dots, X_n$  formam uma a.a. de uma distribuição Uniforme no intervalo  $(0, \theta)$  com  $\theta$  desconhecido ( $\theta > 0$ ). A fdp de cada observação tem a forma:

$$f(x|\theta) = \begin{cases} \frac{1}{\theta} & \text{para } 0 \leq x \leq \theta \\ 0 & \text{c.c.} \end{cases} \quad (9)$$

# Exemplos de EMV

## Amostragem de uma Uniforme

portanto, a distribuição conjunta  $f_n(\mathbf{x}|\theta)$  de  $X_1, X_2, \dots, X_n$  tem a forma:

$$f_n(\mathbf{x}|\theta) = \begin{cases} \frac{1}{\theta^n} & \text{para } 0 \leq x_i \leq \theta \quad (i = 1, \dots, n) \\ 0 & \text{c.c.} \end{cases} \quad (10)$$

Pode se mostrar que o EMV de  $\theta$  deve ser um valor de  $\theta$  para a qual  $\theta \geq x_i$  para  $i = 1, \dots, n$  e maximiza  $1/\theta^n$  entre tais valores. Como  $1/\theta^n$  é uma função decrescente em  $\theta$ , a estimativa será o menor valor de  $\theta$  tal que  $\theta \geq x_i$  para  $(i = 1, \dots, n)$ . Como este valor é  $\theta = \max(x_1, \dots, x_n)$  o EMV de  $\theta$  é  $\hat{\theta} = \max(x_1, \dots, x_n)$ .

# Exemplos de EMV

## Não Existência de um EMV

Suponha que  $X_1, X_2, \dots, X_n$  formam uma a.a. de uma distribuição Uniforme no intervalo  $(0, \theta)$  com  $\theta$  desconhecido ( $\theta > 0$ ). Suponha que em lugar de escrever a fdp como na equação 9 escrevemos da seguinte forma :

$$f(x|\theta) = \begin{cases} \frac{1}{\theta} & \text{para } 0 < x < \theta \\ 0 & \text{c.c.} \end{cases} \quad (11)$$

A única diferença das equações 9 e 11 é que na segunda a desigualdade é estrita. Ambas podem ser usadas como fdp da distribuição uniforme.



# Exemplos de EMV

## Não Existência de um EMV

portanto, se a equação 11 é usada, o EMV de  $\theta$  será o valor de  $\theta$  para a qual  $\theta > x_i$  para  $(i = 1, \dots, n)$  e que maximiza  $1/\theta^n$  entre todos os valores. Note que os possíveis valores de  $\theta$  não incluem o valor de  $\theta = \max(x_1, \dots, x_n)$  desde que  $\theta$  deve ser estritamente maior que cada valor observado  $x_i$  ( $i = 1, \dots, n$ ). Como  $\theta$  pode ser escolhido como um valor arbitrário próximo de  $\max(x_1, \dots, x_n)$  mas não igual a este valor, então segue-se que o EMV de  $\theta$  não existe.

Este exemplo mostra uma dificuldade dos EMV, pois deveria ser irrelevante o uso das equações 9 ou da 11.

# Exemplos de EMV

## Não unicidade dos EMV

Suponha que  $X_1, X_2, \dots, X_n$  formam uma a.a. de uma distribuição Uniforme no intervalo  $(\theta, \theta + 1)$  com  $\theta$  desconhecido  $(-\infty < \theta < \infty)$ . A fdp conjunta tem a forma:

$$f_n(\mathbf{x}|\theta) = \begin{cases} 1 & \text{para } \theta \leq x_i \leq \theta + 1 (i = 1, \dots, n) \\ 0 & \text{c.c.} \end{cases} \quad (12)$$

A condição  $\theta \leq x_i$  para  $(i = 1, \dots, n)$  é equivalente à  $\theta \leq \min(x_1, \dots, x_n)$ . Similarmente,  $x_i \leq \theta + 1$  para  $(i = 1, \dots, n)$  é equivalente a  $\theta \geq \max(x_1, \dots, x_n) - 1$ .

# Exemplos de EMV

## Não unicidade dos EMV

Escrevemos então  $f_n(\mathbf{x}|\theta)$  da seguinte forma:

$$f_n(\mathbf{x}|\theta) = \begin{cases} 1 & \text{para } \max(x_1, \dots, x_n) - 1 \leq x_i \leq \min(x_1, \dots, x_n) \\ 0 & \text{c.c.} \end{cases} \quad (13)$$

Desta forma, é possível seleccionar como EMV de  $\theta$  qualquer valor de  $\theta$  no intervalo  $\max(x_1, \dots, x_n) - 1 \leq \theta \leq \min(x_1, \dots, x_n)$ .

# Outline

- 1 Estimadores Máxima Verossimilhança
  - Estimadores de Máxima Verossimilhança
  - Casos dignos de nota
  - Propriedades dos Estimadores de Máxima Verossimilhança

# Invariância

Suponha que  $X_1, X_2, \dots, X_n$  formam uma a.a. de uma distribuição  $f(x|\theta)$  com  $\theta$  desconhecido, e seja  $\hat{\theta}$  o EMV de  $\theta$ . Para valores observados  $x_1, \dots, x_n$  a função de verossimilhança  $f_n(\mathbf{x}|\theta)$  é maximizado quando  $\hat{\theta} = \theta$ .

Suponha que mudamos o parâmetro tal que expressaremos a função de probabilidade (densidade) em termos de um parâmetro  $\tau = g(\theta)$ , onde  $g$  é uma injeção de  $\theta$ . Denotemos por  $\theta = h(\tau)$  a função inversa. Então a função de distribuição de cada valor observado será  $f[x|h(\tau)]$  e a função de verossimilhança será  $f_n[\mathbf{x}|h(\tau)]$ .

# Invariância

Suponha que  $X_1, X_2, \dots, X_n$  formam uma a.a. de uma distribuição  $f(x|\theta)$  com  $\theta$  desconhecido, e seja  $\hat{\theta}$  o EMV de  $\theta$ . Para valores observados  $x_1, \dots, x_n$  a função de verossimilhança  $f_n(\mathbf{x}|\theta)$  é maximizado quando  $\hat{\theta} = \theta$ .

Suponha que mudamos o parâmetro tal que expressaremos a função de probabilidade (densidade) em termos de um parâmetro  $\tau = g(\theta)$ , onde  $g$  é uma injeção de  $\theta$ . Denotemos por  $\theta = h(\tau)$  a função inversa. Então a função de distribuição de cada valor observado será  $f[x|h(\tau)]$  e a função de verossimilhança será  $f_n[\mathbf{x}|h(\tau)]$ .

# Invariância

Suponha que  $X_1, X_2, \dots, X_n$  formam uma a.a. de uma distribuição  $f(x|\theta)$  com  $\theta$  desconhecido, e seja  $\hat{\theta}$  o EMV de  $\theta$ . Para valores observados  $x_1, \dots, x_n$  a função de verossimilhança  $f_n(\mathbf{x}|\theta)$  é maximizado quando  $\hat{\theta} = \theta$ .

Suponha que mudamos o parâmetro tal que expressaremos a função de probabilidade (densidade) em termos de um parâmetro  $\tau = g(\theta)$ , onde  $g$  é uma injeção de  $\theta$ . Denotemos por  $\theta = h(\tau)$  a função inversa. Então a função de distribuição de cada valor observado será  $f[x|h(\tau)]$  e a função de verossimilhança será  $f_n[\mathbf{x}|h(\tau)]$ .

# Invariância

Como  $f_n(\mathbf{x}|\theta)$  é maximizado quando  $\theta = \hat{\theta}$ , segue-se que  $f_n[\mathbf{x}|h(\tau)]$  será maximizado quando  $h(\tau) = \hat{\theta}$ . Portanto, o EMV  $\hat{\tau}$  deve satisfazer a relação  $h(\hat{\tau}) = \hat{\theta}$  ou,  $\hat{\tau} = g(\hat{\theta})$

Propriedade da invariância:

*Se  $\hat{\theta}$  é o EMV de  $\theta$ , então  $g(\hat{\theta})$  é o EMV de  $g(\theta)$ .*



# Invariância

Como  $f_n(\mathbf{x}|\theta)$  é maximizado quando  $\theta = \hat{\theta}$ , segue-se que  $f_n[\mathbf{x}|h(\tau)]$  será maximizado quando  $h(\tau) = \hat{\theta}$ . Portanto, o EMV  $\hat{\tau}$  deve satisfazer a relação  $h(\hat{\tau}) = \hat{\theta}$  ou,  $\hat{\tau} = g(\hat{\theta})$

Propriedade da invariância:

*Se  $\hat{\theta}$  é o EMV de  $\theta$ , então  $g(\hat{\theta})$  é o EMV de  $g(\theta)$ .*

# Consistência

Em muitos problemas, a sequência de EMV converge em probabilidade ao valor desconhecido de  $\theta$  quando  $n \rightarrow \infty$ .

Foi visto que a sequência de estimadores de Bayes para  $\theta$  é uma sequência consistente de estimadores, portanto, para uma priori dada e uma amostra suficientemente grande, o estimador de Bayes e o EMV de  $\theta$  serão valores muito próximos um do outro e próximos também do valor desconhecido de  $\theta$ .

No exemplo da a.a. extraída de uma Bernoulli, foi mostrado que se a priori de  $\theta$  é uma Beta, então a diferença entre o estimador de Bayes de  $\theta$  e a média amostral  $\bar{X}_n$  converge a 0 quando  $n \rightarrow \infty$ .

Desta forma, as sequências de estimadores de Bayes e a de EMV, são sequências consistentes.

# Consistência

Em muitos problemas, a sequência de EMV converge em probabilidade ao valor desconhecido de  $\theta$  quando  $n \rightarrow \infty$ .

Foi visto que a sequência de estimadores de Bayes para  $\theta$  é uma sequência consistente de estimadores, portanto, para uma priori dada e uma amostra suficientemente grande, o estimador de Bayes e o EMV de  $\theta$  serão valores muito próximos um do outro e próximos também do valor desconhecido de  $\theta$ .

No exemplo da a.a. extraída de uma Bernoulli, foi mostrado que se a priori de  $\theta$  é uma Beta, então a diferença entre o estimador de Bayes de  $\theta$  e a média amostral  $\bar{X}_n$  converge a 0 quando  $n \rightarrow \infty$ .

Desta forma, as sequências de estimadores de Bayes e a de EMV, são sequências consistentes.

# Consistência

Em muitos problemas, a sequência de EMV converge em probabilidade ao valor desconhecido de  $\theta$  quando  $n \rightarrow \infty$ .

Foi visto que a sequência de estimadores de Bayes para  $\theta$  é uma sequência consistente de estimadores, portanto, para uma priori dada e uma amostra suficientemente grande, o estimador de Bayes e o EMV de  $\theta$  serão valores muito próximos um do outro e próximos também do valor desconhecido de  $\theta$ .

No exemplo da a.a. extraída de uma Bernoulli, foi mostrado que se a priori de  $\theta$  é uma Beta, então a diferença entre o estimador de Bayes de  $\theta$  e a média amostral  $\bar{X}_n$  converge a 0 quando  $n \rightarrow \infty$ .

Desta forma, as sequências de estimadores de Bayes e a de EMV, são sequências consistentes.

# Dependência com os planos amostrais

Se o experimentador decide fixar o valor de  $n$  antes de tomar as observações ou preferir usar algum plano amostral, pode ser mostrado que a função de verossimilhança  $L(\theta)$  baseado nos valores observados será:

$$L(\theta) = f(x_1|\theta) \dots f(x_n|\theta)$$

Segue então que o EMV de  $\theta$  será o mesmo, independentemente do plano amostral usado. Em outras palavras, o valor de  $\theta$  depende apenas dos valores observados  $x_1, \dots, x_n$  e não do plano que o experimentador decidiu usar.