

# Chapter 5

## **Joint Probability Distributions and Random Samples**

5.1

# Jointly Distributed Random Variables

# Joint Probability Mass Function

Let  $X$  and  $Y$  be two discrete rv's defined on the sample space of an experiment. The *joint probability mass function*  $p(x, y)$  is defined for each pair of numbers  $(x, y)$  by

$$p(x, y) = P(X = x \text{ and } Y = y)$$

Let  $A$  be the set consisting of pairs of  $(x, y)$  values, then

$$P[(X, Y) \in A] = \sum_{(x, y) \in A} p(x, y)$$

# Marginal Probability Mass Functions

The *marginal probability mass functions* of  $X$  and  $Y$ , denoted  $p_X(x)$  and  $p_Y(y)$  are given by

$$p_X(x) = \sum_y p(x, y) \quad p_Y(y) = \sum_x p(x, y)$$


# Joint Probability Density Function

Let  $X$  and  $Y$  be continuous rv's. Then  $f(x, y)$  is a *joint probability density function* for  $X$  and  $Y$  if for any two-dimensional set  $A$

$$P[(X, Y) \in A] = \iint_A f(x, y) dx dy$$

If  $A$  is the two-dimensional rectangle  $\{(x, y) : a \leq x \leq b, c \leq y \leq d\}$ ,

$$P[(X, Y) \in A] = \int_a^b \int_c^d f(x, y) dy dx$$



$$P[(X, Y) \in A]$$

= Volume under density surface above  $A$

# Marginal Probability Density Functions

The *marginal probability density functions* of  $X$  and  $Y$ , denoted  $f_X(x)$  and  $f_Y(y)$ , are given by

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy \quad \text{for } -\infty < x < \infty$$

$$f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx \quad \text{for } -\infty < y < \infty$$

# Independent Random Variables

Two random variables  $X$  and  $Y$  are said to be *independent* if for every pair of  $x$  and  $y$  values

$$p(x, y) = p_X(x) \times p_Y(y)$$

when  $X$  and  $Y$  are discrete or

$$f(x, y) = f_X(x) \times f_Y(y)$$

when  $X$  and  $Y$  are continuous. If the conditions are not satisfied for all  $(x, y)$  then  $X$  and  $Y$  are *dependent*.



# More Than Two Random Variables

If  $X_1, X_2, \dots, X_n$  are all discrete random variables, the joint pmf of the variables is the function

$$p(x_1, \dots, x_n) = P(X_1 = x_1, \dots, X_n = x_n)$$

If the variables are continuous, the joint pdf is the function  $f$  such that for any  $n$  intervals  $[a_1, b_1], \dots,$

$$\begin{aligned} &[a_n, b_n], \quad P(a_1 \leq X_1 \leq b_1, \dots, a_n \leq X_n \leq b_n) \\ &= \int_{a_1}^{b_1} \dots \int_{a_n}^{b_n} f(x_1, \dots, x_n) dx_n \dots dx_1 \end{aligned}$$

# Independence – More Than Two Random Variables

The random variables  $X_1, X_2, \dots, X_n$  are *independent* if for every subset  $X_{i_1}, X_{i_2}, \dots, X_{i_n}$  of the variables, the joint pmf or pdf of the subset is equal to the product of the marginal pmf's or pdf's.

# Conditional Probability Function

Let  $X$  and  $Y$  be two continuous rv's with joint pdf  $f(x, y)$  and marginal  $X$  pdf  $f_X(x)$ . Then for any  $X$  value  $x$  for which  $f_X(x) > 0$ , *the conditional probability density function of  $Y$  given that  $X = x$*  is

$$f_{Y|X}(y | x) = \frac{f(x, y)}{f_X(x)} \quad -\infty < y < \infty$$

If  $X$  and  $Y$  are discrete, replacing pdf's by pmf's gives the *conditional probability mass function of  $Y$  when  $X = x$* .

## 5.2

# Expected Values, Covariance, and Correlation

# Expected Value

Let  $X$  and  $Y$  be jointly distributed rv's with pmf  $p(x, y)$  or pdf  $f(x, y)$  according to whether the variables are discrete or continuous. Then the *expected value* of a function  $h(X, Y)$ , denoted  $E[h(X, Y)]$  or  $\mu_{h(X,Y)}$

$$\text{is } \begin{cases} \sum_x \sum_y h(x, y) \times p(x, y) & \text{discrete} \\ \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} h(x, y) \times f(x, y) dx dy & \text{continuous} \end{cases}$$

# Covariance

The *covariance* between two rv's  $X$  and  $Y$  is

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$$

$$= \begin{cases} \sum_x \sum_y (x - \mu_X)(y - \mu_Y)p(x, y) & \text{discrete} \\ \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - \mu_X)(y - \mu_Y)f(x, y)dxdy & \text{continuous} \end{cases}$$

# Short-cut Formula for Covariance

$$\text{Cov}(X, Y) = E(XY) - \mu_X \times \mu_Y$$

# Correlation

The *correlation coefficient* of  $X$  and  $Y$ , denoted by  $\text{Corr}(X, Y)$ ,  $\rho_{X,Y}$ , or just  $\rho$ , is defined by

$$\rho_{X,Y} = \frac{\text{Cov}(X, Y)}{\sigma_X \times \sigma_Y}$$



# Correlation Proposition

1. If  $a$  and  $c$  are either both positive or both negative,  $\text{Corr}(aX + b, cY + d) = \text{Corr}(X, Y)$
2. For any two rv's  $X$  and  $Y$ ,  
$$-1 \leq \text{Corr}(X, Y) \leq 1.$$

# Correlation Proposition

1. If  $X$  and  $Y$  are independent, then  $\rho = 0$ ,  
but  $\rho = 0$  does not imply independence.
2.  $\rho = 1$  or  $-1$  iff  $Y = aX + b$   
for some numbers  $a$  and  $b$  with  $a \neq 0$ .

## 5.3

# Estatísticas e suas Distribuições

# Motivações:

As observações de diversas amostras de tamanho  $n$  oriundas da mesma distribuição da população serão geralmente diferentes. Portanto, haverá variações dos valores de qualquer função das observações.

# Estatística

Uma *estatística* é qualquer quantidade cujo valor pode ser calculado dos dados amostrais. Antes de obter os dados, há incerteza sobre o valor que resultará de qualquer estatística específica. Assim, uma estatística é uma v.a. A representaremos por uma letra maiúscula; uma letra minúscula será usada para representar o valor calculado ou observado da estatística.

# Amostras aleatórias

As v.a's  $X_1, \dots, X_n$  são ditos formar uma *amostra aleatória (simples)* de tamanho  $n$  se

1. Os  $X_i$ 's são v.a's independentes.
2. Cada  $X_i$  tem a mesma distribuição de probabilidade.

## A.A's

As condições 1 e 2 são parafraseadas, dizendo que os  $X_i$ 's são v.a's iid. (independentes e idênticamente distribuídos). As condições são satisfeitas:

- No caso de amostragem com reposição ou de uma população infinita.
- Aprox. Quando  $n \ll N$ , na amostragem sem reposição.
- na prática, se  $n/N \leq 0,05$  ( no máx. 5% da população coletada).

# Experimentos de Simulação

As seguintes características devem ser especificadas:

1. A estatística de interesse.
2. A distribuição da população.
3. O tamanho da amostra  $n$ .
4. O número de réplicas  $k$ .



# Distribuição da Média Amostral

# Usando a média amostral

Seja  $X_1, \dots, X_n$  uma a.a. de uma distribuição com média  $\mu$  e desvio padrão  $\sigma$ . Então:

$$1. E(\bar{X}) = \mu \quad \bar{X} = \mu$$

$$2. V(\bar{X}) = \sigma^2 \frac{1}{n} = \frac{\sigma^2}{n}$$

Além disso, com  $T_o = X_1 + \dots + X_n$ ,  
 $E(T_o) = n\mu$ ,  $V(T_o) = n\sigma^2$ , and  $\sigma_{T_o} = \sqrt{n}\sigma$ .


# Distribuição Normal Populacional

Seja  $X_1, \dots, X_n$  uma a.a. De uma distribuição normal com média  $\mu$  e desvio padrão  $\sigma$  .  
Então para qualquer  $n$ ,  $T_o$  e  $\bar{X}$  também são normalmente distribuídos.

# Teorema do Limite Central

Seja  $X_1, \dots, X_n$  uma a.a. de uma distribuição com média  $\mu$  e variância  $\sigma^2$ , então, para  $n$  suficientemente grande,  $\bar{X}$  tem distribuição aproximadamente normal com média  $\mu_{\bar{X}} = \mu$  and  $\sigma_{\bar{X}}^2 = \frac{\sigma^2}{n}$ , e  $T_o$  também tem distribuição aproximada normal com  $\mu_{T_o} = n\mu$ ,  $\sigma_{T_o}^2 = n\sigma^2$ . Quanto maior for o valor de  $n$ , melhor será a aproximação.

# O Teorema do limite central



# Regra de Thumb

Se  $n > 30$ , o Teorema do Limite Central pode ser usado.

# Aproximação à distribuição lognormal

Seja  $X_1, \dots, X_n$  uma a.a. de uma distribuição para a qual são possíveis apenas valores positivos [ $P(X_i > 0) = 1$ ]. Então, se  $n$  é suficientemente grande, o produto  $Y = X_1 X_2 \dots X_n$  tem aproximadamente uma distribuição lognormal.

# Distribuição de uma Combinação Linear



# Combinação Linear

Dada uma coleção de  $n$  v.a  $X_1, \dots, X_n$  e  $n$  constantes numéricas  $a_1, \dots, a_n$ , a v.a

$$Y = a_1X_1 + \dots + a_nX_n = \sum_{i=1}^n a_iX_i$$

É chamada uma *combinação linear* dos  $X_i$ 's.

# Valor esperado de uma Combinação Linear

Sejam  $X_1, \dots, X_n$  com médias  $\mu_1, \mu_2, \dots, \mu_n$  e variâncias de  $\sigma_1^2, \sigma_2^2, \dots, \sigma_n^2$ , respectivamente

Se os  $X_i$ 's são ou não independentes,

$$\begin{aligned} E(a_1 X_1 + \dots + a_n X_n) &= a_1 E(X_1) + \dots + a_n E(X_n) \\ &= a_1 \mu_1 + \dots + a_n \mu_n \end{aligned}$$

# Variancia de uma Combinação Linear

Se  $X_1, \dots, X_n$  são independentes,

$$\begin{aligned} V(a_1X_1 + \dots + a_nX_n) &= a_1^2V(X_1) + \dots + a_n^2V(X_n) \\ &= a_1^2\sigma_1^2 + \dots + a_n^2\sigma_n^2 \end{aligned}$$

e

$$\sigma_{a_1X_1 + \dots + a_nX_n} = \sqrt{a_1^2\sigma_1^2 + \dots + a_n^2\sigma_n^2}$$

# Variância de uma Combinação Linear

Para quaisquer  $X_1, \dots, X_n$ ,

$$V(a_1X_1 + \dots + a_nX_n) = \sum_{i=1}^n \sum_{j=1}^n a_i a_j \text{Cov}(X_i, X_j)$$

# Diferença entre duas V.A's

$$E(X_1 - X_2) = E(X_1) - E(X_2)$$

e, se  $X_1$  e  $X_2$  são independentes,

$$V(X_1 - X_2) = V(X_1) + V(X_2)$$

# Diferença entre v.a's Normais

Se  $X_1, X_2, \dots, X_n$  são v.a iid, então qualquer combinação linear dos  $X_i$ 's também tem distribuição normal. A diferença  $X_1 - X_2$  entre duas v.a's iid normalmente distribuídas, tem também distribuição normal.