

Inferência Estatística

Capítulo 6

Introdução: (pag311)

Estatística: Temos dados da amostra de um evento e precisamos inferir sobre propriedades da distribuição. (indução)

Probabilidade: Temos dados sobre a distribuição e precisamos calcular a probabilidade de um evento. (dedução)

Inferência Estatística:

Notações:

θ é o parâmetro (teta) procurado

Ω é o espaço paramétrico (omega) que contém todos os valores possíveis de θ

$f(x|\theta)$ é uma função probabilidade de um evento, dado o parâmetro θ

Parâmetros θ da distribuição pode ser μ, σ^2 em uma distribuição normal; λ em uma distribuição exponencial, etc.

Amostras aleatórias:

Amostras aleatórias são múltiplos eventos i.i.d. (independentes e identicamente distribuídos).

Notações:

\mathbf{X} = vetor de variáveis X_1, \dots, X_n anteriores ao experimento.

\mathbf{x} = vetor de dados de amostras x_1, \dots, x_n de um experimento.

$f_n(\mathbf{x}|\theta)$ = função de probabilidade conjunta de uma série de eventos, dado θ

$$f_n(\mathbf{x}|\theta) = f_n(x_1, \dots, x_n|\theta) = f(x_1|\theta) \cdot f(x_2|\theta) \cdot \dots \cdot f(x_n|\theta) = \prod_{i=1}^n f(x_i|\theta)$$

Distribuições a priori: (pag313)

Na estatística Bayesiana podemos restringir Ω antes de coletar dados do experimento e/ou fornecer uma distribuição a priori para os valores de θ .

Notações:

$\xi(\theta)$ é uma função de probabilidade (ξ) da distribuição a priori de θ

Distribuições a posteriori: (pag316)

Na estatística Bayesiana, a distribuição a posteriori é um estimador do parâmetro θ depois de ser observados os valores x_1, \dots, x_n da amostra.

Notações:

$\xi(\theta|\mathbf{x})$ é a função de distribuição a posteriori de θ , dado o vetor \mathbf{x}

$\xi(X_1, \dots, X_n)$ ou $\xi(\mathbf{X})$ é um estimador, antes de ter os dados do evento

$\xi(x_1, \dots, x_n)$ ou $\xi(\mathbf{x})$ é uma estimativa, depois de ter os dados do evento

Temos $f_n(\mathbf{x}|\theta)$ e $\xi(\theta)$ e queremos achar $\xi(\theta|\mathbf{x})$. Para isso podemos aplicar Bayes $P(B|A) = P(A|B)P(B)/P(A)$ calculando a função da distribuição marginal de \mathbf{x} independente de θ :

$$g_n(\mathbf{x}) = \int_{\Omega} f_n(\mathbf{x}|\theta) \xi(\theta) d\theta$$

A função da distribuição a posteriori de θ dado \mathbf{x} é

$$\xi(\theta|\mathbf{x}) = \frac{f_n(\mathbf{x}|\theta) \xi(\theta)}{g_n(\mathbf{x})}$$

Podemos chamar $g_n(\mathbf{x})$ de constante k pois não depende de θ

$$k = \frac{1}{\int f_n(\mathbf{x}|\theta) \xi(\theta) d\theta}$$

A função de distribuição de verossimilhança a posteriori de θ é

$$\xi(\theta|\mathbf{x}) = k \cdot f_n(\mathbf{x}|\theta) \cdot \xi(\theta)$$

Exemplo com uma Bernoulli: (pag317)

Um processo de manufatura tem uma probabilidade p desconhecida de fabricar uma peça com defeito.

$$\theta = p$$

$\Omega = 0, \dots, 1$ o domínio de θ é o domínio de p

$\xi(\theta) = 1$ é uma uniforme entre 0 e 1

x é a quantidade de sucessos até que ocorra 1 defeito

Função de probabilidade p é uma Bernoulli

$$P(X=n) = p^n (1-p)^{(1-n)}$$

1. Encontrar a distribuição de cada evento $f(x|\theta)$; Procurando parâmetro θ como sendo a probabilidade p de um evento e x sendo a quantidade de eventos

$$f(x|\theta) = \begin{cases} \theta^x (1-\theta)^{(1-x)} & \text{se } x=0,1 \\ 0 & \text{se outros casos} \end{cases}$$

2. Calcular a distribuição conjunta $f_n(\mathbf{x}|\theta)$; Fazendo o produto de todos os eventos do vetor $\mathbf{x} = x_1, \dots, x_n$

$$f_n(\mathbf{x}|\theta) = \theta^y (1-\theta)^{(n-y)} \text{ quando } y = \sum_{i=1}^n x_i$$

3. Encontrar $\xi(\theta)$ a priori. Não temos uma distribuição a priori, portanto é uma uniforme $\xi(\theta) = 1$

4. Calcular a distribuição de verossimilhança a posteriori $\xi(\theta|\mathbf{x}) = k f_n(\mathbf{x}|\theta) \xi(\theta)$

$$\xi(\theta|\mathbf{x}) = k \theta^y (1-\theta)^{(n-y)} \text{ quando } y = \sum_{i=1}^n x_i$$

5. Encontrar $\xi(\theta|\mathbf{x})$ como sendo uma distribuição f.d.p a posteriori, no caso uma Beta com os parâmetros $\alpha = y+1$ e $\beta = n-y+1$

$$\xi(\theta|\mathbf{x}) = \frac{\Gamma(n+2)}{\Gamma(y+1)\Gamma(n-y+1)} \theta^y (1-\theta)^{n-y} \text{ quando } y = \sum_{i=1}^n x_i$$

Exemplo com uma Exponencial: (pag318)

Uma lâmpada fluorescente tem uma vida útil que segue uma exponencial com parâmetro λ desconhecido. A distribuição a priori do parâmetro λ é uma Gamma com média 0.00002 e desvio padrão 0.0001.

$\alpha/\beta = 0.00002$ é a média da Gamma

$\alpha/\beta^2 = (0.0001)^2$ é a variância da Gamma que é o quadrado do desvio padrão

$f(x) = \lambda e^{-\lambda x}$ função da vida útil que segue uma função exponencial

1. Encontrar a distribuição de cada evento $f(x|\theta)$; foi dado do problema

$$f(x) = \lambda e^{-\lambda x}$$

2. Calcular a distribuição conjunta $f_n(\mathbf{x}|\theta)$; Fazendo o produto de todos os eventos do vetor $\mathbf{x} = x_1, \dots, x_n$

$$f_n(\mathbf{x}|\theta) = \lambda^n e^{(-\lambda y)} \text{ quando } y = \sum_{i=1}^n x_i$$

3. Calcular qual é a distribuição a priori $\xi(\lambda)$

$$\alpha = 4$$

$$\beta = 20000$$

$$\Gamma(\alpha) = \int_0^{\infty} x^{(\alpha-1)} e^{-x} dx = (\alpha-1)!$$

$$\Gamma(x|\alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} \text{ para } x > 0 \text{ e } \Gamma(x|\alpha, \beta) = 0 \text{ para } x \leq 0$$

$$\xi(\lambda) = \frac{(20000)^4}{3!} \lambda^3 e^{-20000\lambda}$$

$$\xi(\lambda) = k \lambda^3 e^{-20000\lambda}$$

4. Calcular a distribuição de verossimilhança a posteriori $\xi(\theta|\mathbf{x}) = k f_n(\mathbf{x}|\theta) \xi(\theta)$

$$\xi(\lambda|\mathbf{x}) = k \cdot \lambda^n e^{(-\lambda y)} \cdot \lambda^3 e^{-20000\lambda} \text{ quando } y = \sum_{i=1}^n x_i$$

$$\xi(\lambda|\mathbf{x}) = k \lambda^{(n+3)} e^{-(y+20000)\lambda} \text{ quando } y = \sum_{i=1}^n x_i$$

5. Encontrar $\xi(\lambda|\mathbf{x})$ como sendo uma distribuição f.d.p a posteriori, no caso uma Gamma com os parâmetros $\alpha = n + 4$ e $\beta = y + 20000$

$$\xi(\lambda|\mathbf{x}) = \frac{(y+20000)^{n+4}}{(n+3)!} \lambda^{(n+3)} e^{-(y+20000)\lambda} \text{ quando } y = \sum_{i=1}^n x_i$$

Observação sequencial: (pag319)

A função a priori de observações sequenciais pode ser incremental, ou pode ser absoluta (sempre se calcula a mesma apriori para toda a sequencia). Em ambos os casos, o resultado é o mesmo.

Distribuição conjugada: (pag321)

Amostragem de uma Bernoulli:

função de probabilidade para um evento

$$f(x|\theta) = \theta^{x_i} (1-\theta)^{1-x_i}$$

função de probabilidade conjunta (para um vetor de eventos)

$$f_n(\mathbf{x}|\theta) = \theta^y (1-\theta)^{n-y}; y = \sum_{i=1}^n x_i$$

para um θ desconhecido $0 < \theta < 1$

a função a priori é uma Beta com parâmetros $\alpha_1 > 0$ e $\beta_2 > 0$

a função a posteriori é uma Beta com parâmetros

$$\alpha_2 = \alpha_1 + \sum_{i=0}^n x_i \text{ e } \beta_2 = \beta_1 + n - \sum_{i=0}^n x_i$$

Amostragem de uma Uniforme:

função de probabilidade para um evento

$$f(x|\theta) = \frac{1}{\theta}; 0 \leq x \leq \theta$$

função de probabilidade conjunta (para um vetor de eventos)

$$f_n(\mathbf{x}|\theta) = \frac{1}{\theta^n}; 0 \leq x_i \leq \theta$$

Amostragem de uma Poisson:

função de probabilidade para um evento

$$f(x|\theta) = \frac{e^{-\theta} \theta^x}{x!}$$

função de probabilidade conjunta (para um vetor de eventos)

$$f_n(\mathbf{x}|\theta) = \left(\prod_{i=1}^n \frac{1}{x_i!} \right) e^{-n\theta} \theta^y; y = \sum_{i=1}^n x_i$$

para um θ desconhecido $0 < \theta$

a função a priori é uma Gamma com parâmetros $\alpha_1 > 0$ e $\beta_1 > 0$

a função a posteriori é uma Beta com parâmetros

$$\alpha_2 = \alpha_1 + \sum_{i=0}^n x_i \text{ e } \beta_2 = \beta_1 + n$$

Amostragem de uma Exponencial:

função de probabilidade para um evento

$$f(x|\theta) = \theta e^{-\theta x}$$

função de probabilidade conjunta (para um vetor de eventos)

$$f_n(\mathbf{x}|\theta) = \theta^n e^{-\theta y}; y = \sum_{i=1}^n x_i$$

para um θ desconhecido $0 < \theta$ e σ_0^2 conhecido $\sigma_0^2 > 0$

a função a priori é uma Gamma com parâmetros $\alpha_1 > 0$ e $\beta_1 > 0$

a função a posteriori é uma Gamma com parâmetros

$$\alpha_2 = \alpha_1 + n \text{ e } \beta_2 = \beta_1 + \sum_{i=0}^n x_i$$

Amostragem de uma Normal:

função de probabilidade para um evento

$$f(x|\mu) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

função de probabilidade conjunta (para um vetor de eventos)

$$f_n(\mathbf{x}|\mu) = \frac{1}{(\sigma\sqrt{2\pi})^{n/2}} e^{-\frac{\sum_{i=1}^n (x_i-\mu)^2}{2\sigma^2}}$$

para uma média θ desconhecida $-\infty < \theta < \infty$ e σ_0^2 conhecido $\sigma_0^2 > 0$

a função a priori é uma Normal com parâmetros μ_1 e σ_1^2

a função a posteriori é uma Normal com parâmetros

$$\mu_2 = \frac{\sigma_0^2 \mu_1 + \sigma_1^2 n \bar{x}_n}{\sigma_0^2 + n \sigma_1^2} \quad \text{e} \quad \sigma_2^2 = \frac{\sigma_0^2 \sigma_1^2}{\sigma_0^2 + n \sigma_1^2}$$

Amostragem de uma Gamma:

função de probabilidade para um evento, esperança e variância

$$f(x|\alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}; x > 0$$

$$E(X) = \frac{\alpha}{\beta}$$

$$VAR(X) = \frac{\alpha}{\beta^2}$$

função de probabilidade conjunta (para um vetor de eventos)

$$f_n(\mathbf{x}|\theta) = \frac{\beta^{n\alpha}}{\Gamma^n(\alpha)} \left(\prod_{i=1}^n x_i\right)^{\alpha-1} e^{(-\beta y)}; y = \sum_{i=1}^n x_i$$

Amostragem de uma Beta:

função de probabilidade para um evento, esperança e variância

$$f(x|\alpha, \beta) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}; 0 < x < 1$$

$$E(X) = \frac{\alpha}{\alpha+\beta}$$

$$VAR(X) = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$$

função de probabilidade conjunta (para um vetor de eventos)

$$f_n(\mathbf{x}|\theta) = \frac{\beta^{n\alpha}}{\Gamma^n(\alpha)} \left(\prod_{i=1}^n x_i\right)^{\alpha-1} e^{(-\beta y)}; y = \sum_{i=1}^n x_i$$

Estimadores de Bayes: (pag330)

Para aplicar a teoria dos estimadores Bayesianos, é necessário:

1. especificar uma função de perda
2. determinar uma função a priori para o parâmetro

Um bom estimador $\delta(\mathbf{X})$ do parâmetro θ é aquele que faz o valor do erro definido por

$\delta(\mathbf{X}) - \theta$ tender a zero. Sendo $a = \delta(\mathbf{x})$ e $a \in \Omega$ uma estimativa de θ . Então $L(\theta, a)$ é a função que mede a diferença entre uma estimativa a e o seu respectivo parâmetro θ .

Diferentes funções de perda:

$$L(\theta, a) = (\theta - a)^2$$

$$L(\theta, a) = |\theta - a|$$

Sendo a esperança $E(x) = \int_{\Omega} x \cdot f(x) dx$ portanto

$$E[L(\theta, a)] = \int_{\Omega} L(\theta, a) \xi(\theta) d\theta$$

A função L para o qual o valor $E[L(\theta, a)]$ será minimizada é chamada de função de perda.

Sendo \mathbf{x} um vetor de dados observados para estimar θ

$$E[L(\theta, a) | \mathbf{x}] = \int_{\Omega} L(\theta, a) \xi(\theta | \mathbf{x}) d\theta$$

A função $\delta^*(\mathbf{X})$ é chamado de estimador de Bayes quando, para cada \mathbf{x} de \mathbf{X} , faz com que $E[L(\theta, \delta^*(\mathbf{x})) | \mathbf{x}] = \min_{a \in \Theta} E[L(\theta, a) | \mathbf{x}]$. Ou seja é o estimador que fornece a menor função de perda.

Diferentes funções de perda:

para $L(\theta, a) = (\theta - a)^2$ então $\delta^*(\mathbf{X}) = E(\theta | \mathbf{X})$ será a média

para $L(\theta, a) = |\theta - a|$ então $\delta^*(\mathbf{X}) = E(|\theta - a| | \mathbf{X})$ será a mediana

para $L(\theta, a) = |\theta - a|^k$ e $k \in \mathbb{N}$ ou $k > 2$ então $L(\theta, a) = \lambda(\theta) |\theta - a|^2$

O estimador de Bayes para a função de perda quadrática é:

$$\delta^*(\mathbf{X}) = E(\theta | \mathbf{X})$$

O estimador de Bayes genérico é:

$$\delta^*(\mathbf{X}) = E(L(\theta, a) | \mathbf{X}) = \int_{\Omega} L(\theta, a) \xi(\theta | \mathbf{x}) d\theta$$

Estimador de Bayes com função de perda quadrática para Bernouli:

Sendo a posteriori $\xi(\theta | \mathbf{x})$ uma Beta com parâmetros

$$\alpha_2 = \alpha_1 + y \text{ e } \beta_2 = \beta_1 + n - y \text{ sendo } y = \sum_{i=0}^n x_i$$

Sendo a esperança para a Beta

$$E(X) = \frac{\alpha}{\alpha + \beta}$$

O estimador de Bayes com função de perda quadrática para uma posteriori Beta é

$$\delta^*(\mathbf{X}) = \frac{\alpha_1 + y}{\alpha_1 + \beta_1 + n} \text{ sendo } y = \sum_{i=0}^n x_i$$

Estimador de Bayes com função de perda quadrática para Normal:

Sendo a posteriori $\xi(\theta | \mathbf{x})$ uma Normal $N(\theta, \sigma^2)$ e uma distribuição a priori $\xi(\theta)$ conhecida $N(\mu, \nu^2)$.

O estimador de Bayes com função de perda quadrática para uma posteriori Normal é

$$\delta^*(\mathbf{X}) = \frac{\sigma^2 \mu + n \nu^2 \bar{X}_n}{\sigma^2 + n \nu^2}$$

Estimadores de Bayes para grandes amostras: (pag335)

Para grandes amostras $n \rightarrow \infty$, mesmo partindo de funções a priori diferentes, a estimativa converge para o valor de θ .

Estimador de máxima verossimilhança (EMV): (pag338)

Estimador de máxima verossimilhança é o estimador $\hat{\theta}$ cuja estimativa θ aplicada à função $f_n(\mathbf{x}|\theta)$ tenha a maior probabilidade de gerar o vetor de dados \mathbf{x} .

Notação:

$\hat{\theta}$ (teta chapéu) é o estimador de máxima verossimilhança

$L(\theta) = \log f_n(\mathbf{x}|\theta)$ é o log da função de probabilidade conjugada

O estimador de máxima verossimilhança (MVE) é o ponto máximo de $L(\theta)$ ou seja

$$\text{MVE é } \frac{dL(\theta)}{d\theta} = 0 \text{ ou } \frac{d}{d\theta}(\log f_n(\mathbf{x}|\theta)) = 0$$

O EMV pode ser único, pode ser múltiplo ou pode ser inexistente.

Exemplo de EMV para uma Bernoulli

$$f_n(\mathbf{x}|\theta) = \prod_{i=1}^n \theta^{x_i} (1-\theta)^{1-x_i} = \theta^y (1-\theta)^{n-y}; y = \sum_{i=1}^n x_i$$

Aplicando um log.

$$L(\theta) = \log f_n(\mathbf{x}|\theta) = y \log \theta + (n-y) \log(1-\theta); y = \sum_{i=1}^n x_i$$

O ponto de máxima de $L(\theta)$ é $dL(\theta)/d\theta = 0$, encontramos

$$\hat{\theta} = \bar{x}_n$$

Mortanto o EMV de θ para uma Bernoulli é

$$\hat{\theta} = \bar{X}_n$$

Exemplo de EMV para uma Normal com média e variância desconhecidas.

$$\hat{\mu} = \bar{X}_n \text{ e } \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_n)^2$$

Propriedades do estimador de máxima verossimilhança: (pag338)

Estatística suficiente: (pag356)

Estatística suficiente é quando, dado observações de uma amostra x_1, x_2, \dots, x_n , uma estatística $T = r(x_1, x_2, \dots, x_n)$ e sendo função r o EMV, T é a melhor estimativa da observação, podendo substituir os dados da amostra sem nenhuma perda no resultado final.

Para uma Bernoulli $f_n(\mathbf{x}|\theta) = \theta^y (1-\theta)^{n-y}; y = \sum_{i=1}^n x_i$, são estatística suficiente n $y = \sum_{i=1}^n x_i$ pois eles substituem totalmente a amostra x_1, x_2, \dots, x_n .

Estatísticas suficientes mais comuns

$\bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i$ é a média amostral

$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x}_n)^2$ é a variância amostral

$x_{(1)} = \min(\mathbf{x}) = \min(x_1, \dots, x_n)$ o menor valor da amostra

$x_{(n)} = \max(\mathbf{x}) = \max(x_1, \dots, x_n)$ o maior valor da amostra

$x_{(i)}$ a i-ésima maior observação da amostra

Limites de estatísticas suficientes.

Estimador rubusto é um estimador suficiente para ampla variedade de possíveis f.d.p's.

Estimadores não Viesados:

Um estimador não viesado $\delta(\mathbf{X})$ tem sua esperança $E[\delta(\mathbf{X})]$ igual ao valor desconhecido verdadeiro de θ .

Exemplo: se a média é a esperança da média amostral $\mu = E(\bar{X}_n)$, um estimador não viesado da média $\delta(\mu) = \bar{X}_n$ é a média amostral.

Estimadores não viesados (ENV):

$\delta(\mu) = \bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i$ um ENV da média é a média amostral

$\delta(\sigma^2) = S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x}_n)^2$ um ENV da variância é a variância amostral

Teste de Hipóteses

Capítulo 8

Problemas de teste de hipótese: (pag 437)

Em um problema estatístico envolvendo o parâmetro θ , cujo valor desconhecido pertence ao espaço Ω , alguns valores de θ podem ser satisfatórios para uma determinada hipótese H_0 .

Hipótese nula e alternativa: (pag 437)

O conjunto dos valores satisfatórios é chamado de Ω_0 e o conjunto dos valores não satisfatórios é chamado de Ω_1 .

Notação:

H_0 Hipótese nula $\theta \in \Omega_0$, ou seja, hipótese de interesse

H_1 Hipótese alternativa $\theta \in \Omega_1$

θ Parâmetro que está sendo testado

Ω_0 Espaço paramétrico da hipótese nula (teta zero), ou seja, de interesse.

Ω_1 Espaço paramétrico da hipótese alternativa (teta um)

Ω Espaço paramétrico total (teta) onde $\Omega_0 \cup \Omega_1 = \Omega$

$\theta = \theta_0$ Parâmetro dentro do espaço paramétrico da hipótese nula $\theta \in \Omega_0$

$\theta = \theta_1$ Parâmetro dentro do espaço paramétrico da hipótese alternativa $\theta \in \Omega_1$

Região Crítica: (pag 438)

Região do espaço amostral S_1 que rejeita a hipótese nula, ou seja, que está associada ao parâmetro dentro da hipótese alternativa $\theta \in \Omega_1$.

Notação:

S Espaço amostral

S_0 Espaço amostral que aceita a hipótese nula

S_1 ou C ou RC **Região crítica** é o espaço amostral que rejeita a hipótese nula

Função Poder: (pag 438)

É a função $\pi(\theta)$ que dá a probabilidade de rejeitar a hipótese nula H_0 . Ou seja é a probabilidade de $\theta \in \Omega_1$. A função poder, como toda probabilidade, varia no intervalo de zero a um.

Notação:

$\pi(\theta)$ = função poder (π) é a probabilidade de $\theta \in \Omega_1$ ou seja, rejeitar H_0

\mathbf{x} = vetor de dados de amostras x_1, \dots, x_n de um experimento

$f(x|\theta)$ = função de probabilidade de um evento, dado θ

$F(x|\theta)$ = função de probabilidade acumulada de um evento, dado θ

$f_n(\mathbf{x}|\theta)$ = função de probabilidade conjunta de uma série de eventos, dado θ

Probabilidade conjunta:

$$f_n(\mathbf{x}|\theta) = f_n(x_1, \dots, x_n|\theta) = f(x_1|\theta) \cdot f(x_2|\theta) \cdot \dots \cdot f(x_n|\theta) = \prod_{i=1}^n f(x_i|\theta)$$

Função poder:

$$\pi(\theta) = f_n(\mathbf{x} \in S_1|\theta); \theta \in \Omega$$

Tamanho do Teste:

Tamanho do teste α é a maior probabilidade, entre todos os valores de θ , que satisfaça a hipótese nula em não fazer uma decisão errada.

Notação:

α_0 = nível de significância $0 < \alpha_0 < 1$

α = tamanho do teste

Tamanho do teste:

$$\alpha = \sup_{\theta \in \Omega} \pi(\theta|\delta)$$

Para uma hipótese nula simples, o tamanho do teste é

$$\alpha = \pi(\theta_0|\delta)$$

Teste:

Um teste δ é a definição de uma função poder $\pi(\theta|\delta)$.

Notação:

$\pi(\theta|\delta)$ = função poder (π) de um teste δ

$\alpha(\delta)$ = tamanho do teste δ

Roteiro:

- (1) Identificar o parâmetro θ e sua distribuição
 $Uniforme(0, \theta)$ ou $Uniforme(\theta, 0)$
 $Normal(\theta, \sigma^2)$
 $Poisson(\theta)$
 $Exponencial(\theta)$
 $Polinomial(\theta)$
- (2) Identificar a hipótese de interesse H_0
 $H_0 = 3 \leq \theta \leq 4$
- (3) Identificar o espaço paramétrico Ω , Ω_0 e Ω_1
 Ω Espaço paramétrico total (teta) onde $\Omega_0 \cup \Omega_1 = \Omega$
 Ω_0 Espaço paramétrico da hipótese nula (teta zero), ou seja, de interesse.
 Ω_1 Espaço paramétrico da hipótese alternativa (teta um)
Traçar a linha do espaço paramétrico
- (4) Identificar o teste δ com o seu espaço amostral S_1
 S_1 ou C ou RC **Região crítica** é o espaço amostral que rejeita a hipótese nula
Traçar a linha do espaço amostral
- (5) identificar a função a acumulada $F(x|\theta)$ e a conjunta $f_n(\mathbf{x}|\theta)$
 $f(x|\theta)$ para $x=k$
 $F(x|\theta)$ para $k \leq x \leq m$
 $f_n(\mathbf{x}|\theta)$ a função conjugada
- (6) Achar a função poder para cada sub-espaço do espaço paramétrico
se $\pi(\theta \in \Omega_a | \delta)$ calcular $f_n(\mathbf{x} \in S_{1a} | \theta) + f_n(\mathbf{x} \in S_{1b} | \theta) + \dots$
se $\pi(\theta \in \Omega_b | \delta)$ calcular $f_n(\mathbf{x} \in S_{1a} | \theta) + f_n(\mathbf{x} \in S_{1b} | \theta) + \dots$
- (7) Calcular o tamanho do teste
 $\alpha(\delta) = \sup_{\theta \in \Omega} \pi(\theta | \delta)$

Exemplo:

Dada uma amostra aleatória x_1, \dots, x_n de uma distribuição uniforme no intervalo de $(0, \theta)$ sendo θ desconhecido e $\theta > 0$. A hipótese testa é $H_0 = 3 \leq \theta \leq 4$.

Estimativa suficiente para o máximo da uniforme é

$$x_{(n)} = \max(x_1, \dots, x_n)$$

O teste pode ser definido como, a hipótese será expandida para $H_0 = 2.9 \leq \theta \leq 4$ portanto

$$\pi(\theta | \delta) = P(x_{(n)} < 2.9 | \theta) + P(x_{(n)} > 4 | \theta)$$

$$f(x|\theta) = \frac{1}{\theta}$$

$$F(x < 2.9 | \theta) = \frac{2.9}{\theta}$$

$$f_n(\mathbf{x}_{(n)} < 2.9 | \theta) = \left(\frac{2.9}{\theta}\right)^n$$

$$F(x > 4 | \theta) = 1 - F(x < 4 | \theta) = 1 - \frac{4}{\theta}$$

$$f_n(\mathbf{x}_{(n)} < 4 | \theta) = 1 - \left(\frac{4}{\theta}\right)^n$$

Calculando a função poder

$$\pi(\theta|\delta) = \left(\frac{2.9}{\theta}\right)^n + 1 - \left(\frac{4}{\theta}\right)^n$$

Calculando o tamanho do teste

$$\alpha = \sup_{\theta \in \Omega} \pi(3) = \left(\frac{2.9}{3}\right)^n$$

Testando hipótese simples: (pag 442)

Erro tipo 1: Rejeitar hipótese H_0 quando de fato ela é verdadeira.

Erro tipo 2: Aceitar hipótese H_0 quando de fato ela é falsa.

δ Procedimento de teste

Erro tipo 1

$$\alpha(\theta) = P(\text{rejeitar } H_0 | \theta = \theta_0)$$

Erro tipo 2

$$\beta(\theta) = P(\text{aceitar } H_0 | \theta = \theta_1)$$

O ideal é encontrar um procedimento de teste que mantenha $\alpha(\theta)$ e $\beta(\theta)$ o menor possível.

Minimizando a combinação linear

$$a\alpha(\delta^*) + b\beta(\delta^*) \leq a\alpha(\delta) + b\beta(\delta)$$

Minimizando a combinação linear

$$\begin{aligned} a\alpha(\delta_1) + b\beta(\delta_1) &= a \sum_{x \in R} f_0(x) + b \sum_{x \in R^c} f_1(x) \\ &= a \sum_{x \in R} f_0(x) + b \left(1 - \sum_{x \in R} f_1(x)\right) \\ &= b + \sum_{x \in R} [af_0(x) - bf_1(x)] \end{aligned}$$

Problema de multi-decisão: (pag 456)

Teste uniformemente mais poderoso: (pag 466)

Selecionando procedimento de teste: (pag 477)

Teste T: (pag 485)

Discussão sobre metodologia de teste de hipótese: (pag 494)

Distribuição F: (pag 499)

Comparando média de duas distribuições normais: (pag 506)