

## Modelos Especiais

tradução do Jay Davore e do livro Análise de variância (W.BUSSAB)

# Índice

## 1 Introdução

- Reta passando pela origem
- Regressão Linear para séries de tempo
- Transformação de variáveis
- Modelo Exponencial
- Alguns modelos Linearizáveis

# Introdução

Suponha o modelo

$$Y = \beta x + \epsilon$$

com as mesmas suposições do MRLS. E seja observada uma amostra  $(x_i, y_i)$  com  $i = 1, \dots, n$ . Neste modelo, a soma de quadrados a ser minimizada é

$$\sum \epsilon_i^2 = \sum (y_i - \beta x_i)^2 = SQ(\beta)$$

Derivando e igualando a zero temos:

$$b = \hat{\beta} = \frac{\sum x_i y_i}{\sum x_i^2}$$

# Introdução

Os resultados para o modelo são:

- $E(b) = \beta$  e  $var(b) = \frac{\sigma_\epsilon^2}{\sum x_i^2}$
- $E(s_\epsilon^2) = \sigma_\epsilon^2$ , onde

$$s_\epsilon^2 = \frac{1}{n-1} \sum (y_i - \hat{y}_i)^2 = \frac{1}{n-1} \left\{ \sum y_i^2 - b^2 \sum x_i^2 \right\}$$

- a estatística  $t$ :

$$t_b = \frac{b - \beta}{s_\epsilon} \sqrt{\sum x_i^2} \sim t_{n-1} \quad g.l.$$

# Introdução

- $E(\hat{\mu}(x)) = E(\hat{y}|x) = \beta x \quad \text{var}(\hat{\mu}(x)) = \frac{\sigma_{\epsilon} x^2}{\sum x_i^2}$
- o IC para  $\mu$  ao 95% é

$$IC[\mu(x), 1 - \alpha] = \hat{y} \pm t_{\alpha/2, n-2} s_{\epsilon} * \frac{x}{\sqrt{\sum x_i^2}}$$

- o IC para  $Y(x)$  é

$$IC(Y(x), 1 - \alpha) = \hat{y} \pm t_{\alpha/2, n-1} s_{\epsilon} * \sqrt{1 + \frac{x^2}{\sum x_i^2}}$$

# ANOVA

Devemos observar que quando  $\beta = 0$  o modelo será:

$$y = 0 + \epsilon$$

e devemos comparar a diminuição entre o resíduo deste modelo que não tem parâmetros a serem estimados com o modelo  $y = \beta x + \epsilon$  (um parâmetro).

Para o modelo com  $\beta = 0$  teremos:

$$SQ_{Tot} = SQT = \sum (y_i - 0)^2 = \sum y_i^2$$

$$SQ_{Res} = \sum (y_i - \hat{y}_i)^2 = \sum y_i^2 - b^2 \sum x_i^2$$

portanto a diminuição será:

$$SQ_{Reg} = SQT - SQ_{Res} = b^2 \sum x_i^2$$

# ANOVA

Para testar  $\beta = 0$  usamos:

$$t_b = \frac{b}{s_\epsilon} \sqrt{\sum x_i^2} \quad ou \quad t_b^2 = \frac{b^2 \sum x_i^2}{s_\epsilon^2} = \frac{SQReg}{s_\epsilon^2} = F$$

# ANOVA

o coeficiente  $R^2$  passa a ser

$$R^2 = \frac{SQReg}{SQT} = \frac{b^2 \sum x_i^2}{\sum y_i^2}$$

As informações são resumidas abaixo:

ANOVA Modelo  $\hat{y} = bx$

Fonte	gl	SQ	QM	F
Regressão	1	$b^2 \sum x_i^2$	$b^2 \sum x_i^2$	$F = \frac{b^2 \sum x_i^2}{s_\epsilon^2}$
Resíduo	8	$\sum y_i^2 - b^2 \sum x_i^2$	$s_\epsilon^2$	
Total	9	$\sum y_i^2$	$\hat{\sigma}^2$	$R^2 = \frac{b^2 \sum x_i^2}{\sum y_i^2}$



## Exemplo

Fonte	gl	SQ	QM	F
Regressão	1	382908,69	382909	F=157488
Resíduo	8	47,31	2,43318	
Total	9	383028	42559	$R^2 = 99,97\%$

## Exemplo

É necessário cautela sobre o uso do modelo, pois ela pode servir para um intervalo e não para valores fora dela.

É, portanto, importante, ter cuidado na hora de fazer previsões,

# Introdução

- Intentamos entender a variabilidade de um fenômeno em função do tempo
- Neste caso, a variável auxiliar será o tempo
- o modo de análise é idêntico ao apresentado nos capítulos anteriores

## Representação Gráfica

- O primeiro passo para investigar o tipo de modelo a ser adotado é a representação gráfica dos dados observados, a qual pode sugerir a forma da curva relacionando as variáveis.
- Por exemplo, podemos ver um modelo do tipo

$$f(x) = \alpha e^{\beta x}$$

Adaptando às condições conhecidas, teríamos

$$Y = \alpha e^{\beta x} + f$$

- a mudança da variável residual  $f$  é para não confundir a constante e que aparece no modelo.

# Representação gráfica

- A derivação dos estimadores MQ será:

$$SQ(\alpha, \beta) = \sum f^2 = (y_i - \alpha e^{\beta x_i})^2$$

- derivando com respeito de  $\alpha$  e de  $\beta$

$$\frac{\partial S}{\partial \alpha} = -2 \sum (y_i - a e^{bx_i}) e^{bx_i} = 0$$

$$\frac{\partial S}{\partial \beta} = -2 \sum (y_i - a e^{bx_i}) a e^{bx_i} x_i = 0$$

## Representação gráfica

Obtemos finalmente as equações:

$$a \sum e^{2bx_i} = \sum y_i e^{bx_i}$$

$$a^2 \sum x_i e^{2bx_i} = a \sum x_i y_i e^{bx_i}$$

A solução exata deste sistema de equações exige a adoção de técnicas de soluções numéricas.

Esta dificuldade sugere o emprego de modelos alternativos mais simples , ou ainda a transformação das variáveis envolvidas de modo a reduzir o problema a casos já conhecidos.

# Introdução

Para exemplificar como a transformação das variáveis pode reduzir um modelo mais complexo num outro linear. Para o exemplo, se aplicamos o logaritmo:

$$\ln f(x) = \ln(\alpha e^{\beta x}) = \ln \alpha + \beta x$$

e reescrevendo:

$$Y' = \ln Y \quad e \quad \alpha' = \ln \alpha$$

podemos escrever o modelo linear

$$Y' = \alpha' + \beta x + \epsilon$$

# Modelos

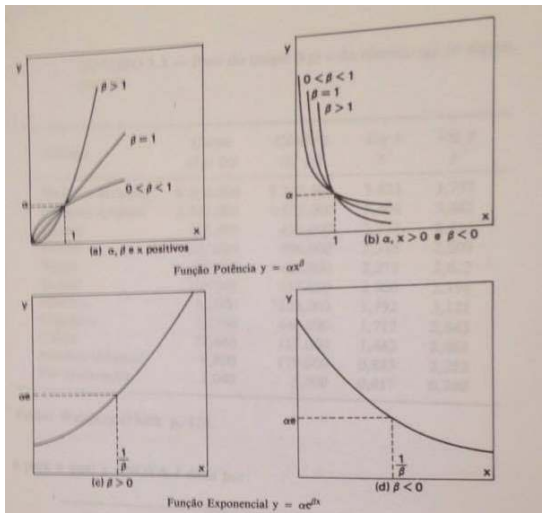
- Estamos interessados em funções que através de transformações de variáveis reduzem-se a modelos lineares do tipo  $f(x) = \alpha + \beta x$ .
- o conhecimento da forma de diversas famílias de curva, ajuda-nos a decidir por um dado modelo
- Os modelos obtidos através de análise gráfica exigem cuidados especiais tanto na sua utilização para previsão como para interpretação. No primeiro caso, devemos tomar precauções nas extrapolações. Já para a interpretação das estimativas dos parâmetros, lembre que na maioria dos casos interessa-nos a relação no modelo original e não no transformado, devido à complexidade, a interpretação torna-se difícil.
- É obrigatório a análise de resíduos.



# Algumas transformações

Figura	Função	transformações	Forma Linear	Observações
(a)(b)	$y = \alpha x^\beta$	$y' = \log(y),$ $x' = \log(x)$	$y' = \log(\alpha) + \beta x'$	$y > 0$ $x > 0$
(c)(d)	$y = \alpha e^{\beta x}$	$y' = \ln(y)$	$y' = \alpha + \beta x'$	$y > 0$
(e)(f)	$y = \alpha + \beta \log(x)$	$x' = \log(x)$	$y = \alpha + \beta x'$	$x > 0$
(g)(h)	$y = \frac{x}{\alpha x - \beta}$	$y' = \frac{1}{y'},$ $x' = \frac{1}{x}$	$y' = \alpha - \beta x'$	$y \neq 0$ e $x \neq 0$
(i)	$y = \frac{e^{\alpha + \beta x}}{1 + e^{\alpha + \beta x}}$	$y' = \ln\left(\frac{y}{1-y}\right)$	$y' = \alpha + \beta x$	

# Exemplo



# Exemplo

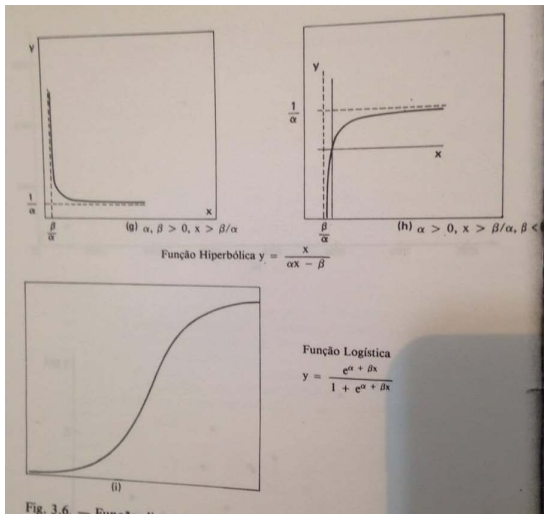


Fig. 3.6. — Funções...