



Inteligência Artificial

Profa. Patrícia R. Oliveira
EACH / USP

Parte 8 – Algoritmos Genéticos

Este material é parcialmente baseado em slides
dos Profs. Thiago Pardo (ICMC/USP), Marcílio de Souto (UFRN) e
Joseana Fechine (UFCG)



Introdução

- Algoritmos Genéticos (AG's) são modelos de processamento computacional que simulam os mecanismos de seleção natural, genética e evolução.
 - Muito aplicados a problemas de otimização.
- Introduzidos por John Holland em 1975.
- Quanto melhor um indivíduo se adaptar ao seu meio ambiente, maior será sua chance de sobreviver e gerar descendentes
 - As hipóteses boas se perpetuam.

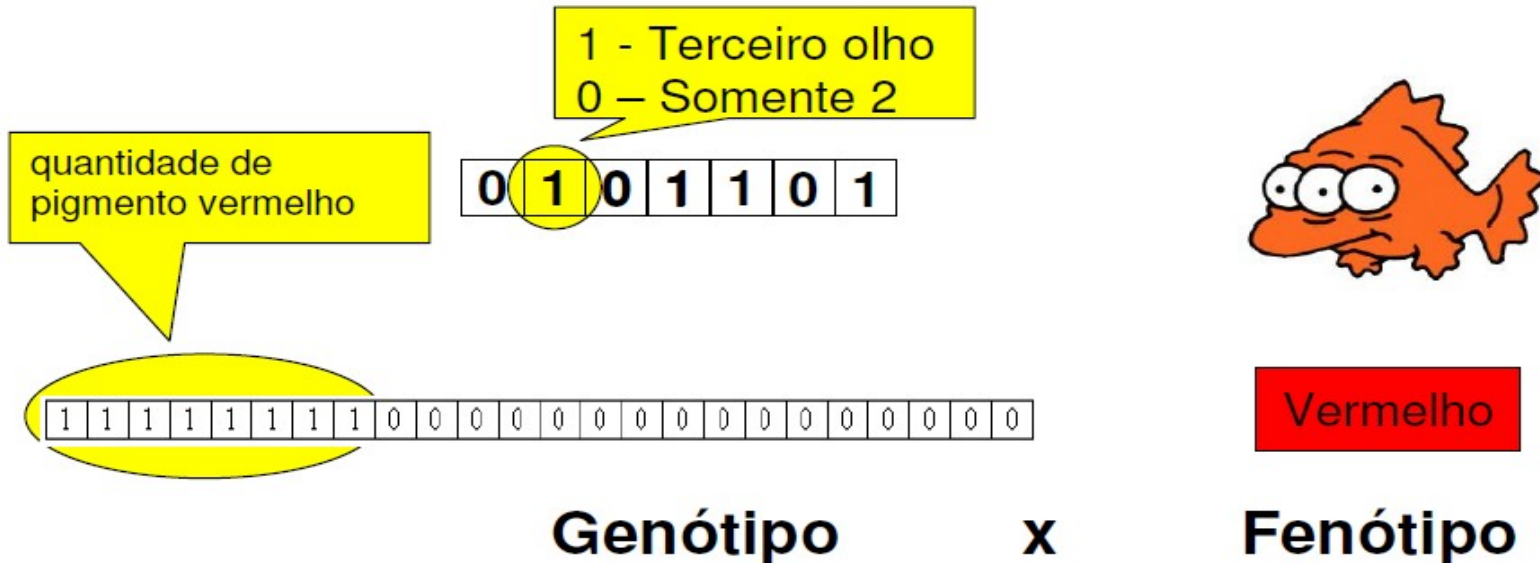


Seleção Natural

- Idéia principal dos AG's é baseada no conceito de Seleção Natural:
 - Indivíduos mais aptos têm mais chance de sobreviver e ter mais descendentes.
 - Espalham seus genes.
 - Indivíduos menos aptos geram poucos ou nenhum descendente.
 - Tendem a desaparecer.

Definições

- Cada solução/hipótese candidata é considerada como um indivíduo.
- Indivíduo representado por um cromossomo (cadeia de bits).
- Um gene é a porção de um cromossomo que codifica uma característica específica do indivíduo.






Utilizando AG's

- Geralmente, os AG têm apenas dois componentes dependentes do problema:
 - Codificação das soluções em cromossomos.
 - Definição da função de aptidão.

Função de Aptidão

- Na natureza, a seleção é realizada pela pressão do meio ambiente.
- No contexto computacional, é simulada pela aplicação da função de aptidão.





Função de Aptidão

- A função de aptidão tem por objetivo fornecer uma medida de aptidão de cada indivíduo na população atual.
 - Capacidade para sobreviver, se reproduzir e manter seu código genético nas próximas gerações.
- Geralmente é uma expressão matemática que mede o quanto uma solução está próxima da solução desejada
 - Específica de cada problema.
- Depende do desempenho do fenótipo, mas é calculada a partir do genótipo.

Codificação dos Cromossomos

- Representação das possíveis soluções do espaço de busca do problema por cromossomos.
- Representação padrão: binária.

■ Ex.: Maximizar $f(x) = -x^2 + 8x + 3$


0	0	0	1	1
---	---	---	---	---

0	1	0	0	0
---	---	---	---	---

Cromossomos

$X = 3$

$X = 8$





Características dos AG's

- Trabalham com codificações das soluções (genótipo), e não com as soluções (fenótipo).
- Buscam a partir de uma população, e não de um único ponto.
 - Realizam buscas simultâneas em várias regiões do espaço de busca.
- Utilizam apenas função de avaliação (fitness).
- Não utilizam derivadas ou outro conhecimento auxiliar.
 - Utilizam regras de transição probabilísticas e não determinísticas.



Funcionamento Básico

- O algoritmo é iniciado com uma população inicial (soluções/hipóteses iniciais)
- A população sofre evolução
 - 1. Seleção de uma porcentagem da população para a nova população
 - 2. Operadores genéticos: cruzamento (crossover) e mutação
 - Cruzamento de elementos selecionados para comporem a nova população.
 - Mutação de alguns elementos da nova população
- Algoritmo executado ciclicamente até que seu critério de parada seja satisfeito.




Seleção

- Escolha dos indivíduos da população atual para reprodução: mais aptos têm mais chances.
- Direciona a evolução da população.
- Projetada para escolher preferencialmente indivíduos com maiores notas de aptidão, embora não exclusivamente.
 - Mantém a diversidade da população.

Seleção – Método da Roleta

- Baseado na aptidão relativa (probabilidade de seleção).
- Cada vez que a roleta é girada, escolhe-se um indivíduo.

Indivíduo	Aptidão	Aptidão
S_i	$f(S_i)$	Relativa
S_1 10110	2.23	0.14
S_2 11000	7.27	0.47
S_3 11110	1.05	0.07
S_4 01001	3.35	0.21
S_5 00110	1.69	0.11





Seleção – Método da Roleta

- Método de seleção mais simples e mais utilizado.
- Representatividade de um indivíduo na roleta proporcional a sua aptidão.
- Cada vez que a roleta é girada, é escolhido um indivíduo.
- O processo é repetido até preencher a população intermediária.
 - de potenciais cromossomos “pais”.


Exemplo

Number of individual	1	2	3	4	5	6	7	8	9	10	11
fitness value	2.0	1.8	1.6	1.4	1.2	1.0	0.8	0.6	0.4	0.2	0.0
selection probability	0.18	0.16	0.15	0.13	0.11	0.09	0.07	0.06	0.03	0.02	0.0

- A tabela acima mostra as probabilidades de seleção para 11 indivíduos, junto com seus valores de aptidão.
- Para formar a população intermediária, com 6 indivíduos, foram gerados 6 números aleatórios entre 0 e 1:

0.81, 0.32, 0.96, 0.01, 0.65, 0.42


- Processo de seleção para os 6 giros da roleta (trials).



- Foram selecionados os indivíduos: 1, 2, 3, 5, 6, 9.

Seleção – Amostragem Universal Estocástica

- Variação do método da roleta.
- P ponteiros igualmente espaçados.
 - P é o número de indivíduos a serem selecionados para a próxima geração.
- A roleta é girada uma única vez.




Exemplo

Number of individual	1	2	3	4	5	6	7	8	9	10	11
fitness value	2.0	1.8	1.6	1.4	1.2	1.0	0.8	0.6	0.4	0.2	0.0
selection probability	0.18	0.16	0.15	0.13	0.11	0.09	0.07	0.06	0.03	0.02	0.0

- Para os 6 indivíduos a serem selecionados, a distância entre os ponteiros é $1/6=0.167$
- Para formar a população intermediária, foi gerado o único número aleatório entre 0 e 1:

0.1

- Processo de seleção para o único giro da roleta.



- Foram selecionados os indivíduos: 1, 2, 3, 4, 6, 8.

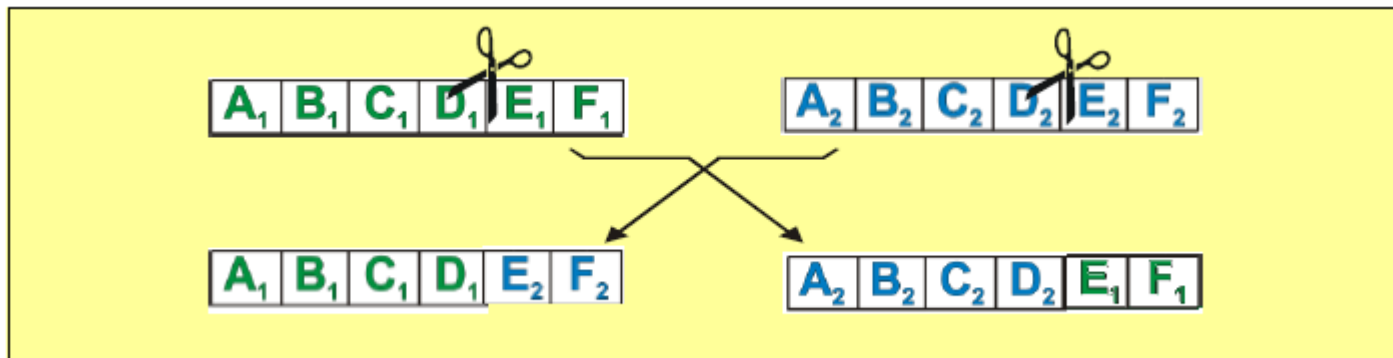


Operadores Genéticos

- A etapa de seleção, gera uma população intermediária de potenciais cromossomos pais.
- Na nova geração, escolhe-se aleatoriamente dois pais para aplicação de operadores genéticos (crossover e mutação).
- Produção de filhos é feita até completar o tamanho da população desejada.


Cruzamento (Crossover)

- Genitores selecionados trocam partes de seus cromossomos entre si.
- Características genéticas dos genitores mantidas.
- Definida uma fração de elementos que sofrerá cruzamento.
- Crossover de um ponto:




Cruzamento (Crossover)

- Crossover de dois pontos:






- Crossover uniforme:





Cruzamento (Crossover)

- Possibilidade do uso de máscaras: o bit na posição i de cada descendente é copiado do bit na posição i de um dos pais.




Mutação

- Altera aleatoriamente o código genético de um indivíduo.
- Geralmente utiliza-se uma taxa de mutação pequena (entre 0,001 e 0,1).

Antes da mutação

0	1	0	1	1	0	1
---	---	---	---	---	---	---



Depois da mutação

0	1	0	1	1	1	1
---	---	---	---	---	---	---





Mutação

- Necessária para a introdução e manutenção da diversidade genética da população.
 - Resultado positivo: sobrevivência.
 - Resultado negativo: extinção.
- Torna possível a exploração de novas áreas do espaço de busca que não poderiam ser alcançadas somente com os cruzamentos aplicados à população inicial.
 - Ajuda a evitar ótimos locais.



Estratégia Elitista

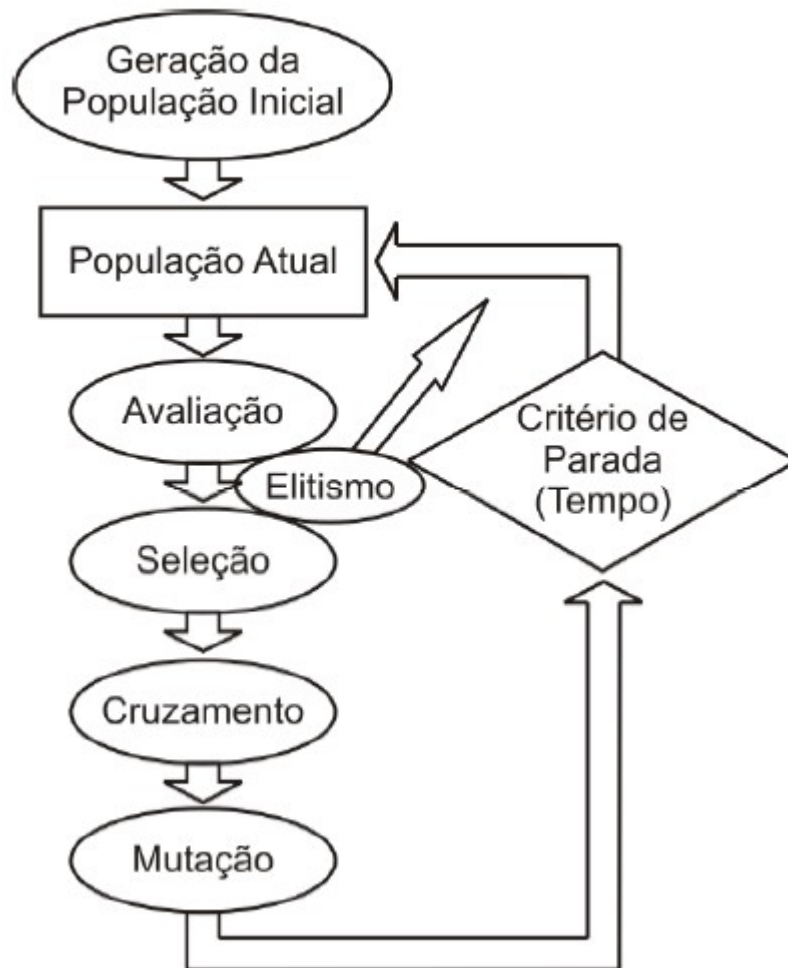
- Durante a evolução dos AG's, pode acontecer de o indivíduo mais apto de uma geração não estar presente na geração seguinte.
 - Característica não-determinística dos AG's.
- Com a estratégia elitista, o(s) melhor(es) indivíduos são automaticamente colocados na próxima geração.
 - Para prevenir que não desapareçam da população pela manipulação dos operadores genéticos.



Critério de Parada

- Número de gerações
- Estagnação da aptidão média da população
- Estagnação da aptidão do melhor indivíduo da população
- Homogeneidade das aptidões dos indivíduos da população

Esquema Básico dos AG's





Parâmetros dos AG's

- O desempenho dos AG é fortemente influenciado pela definição dos seus parâmetros
- Tamanho da população
 - Populações pequenas: cobrem pouco o espaço de busca.
 - Populações grandes: apesar de evitar mínimos locais, requer mais recursos computacionais e tempo.
- Intervalo de geração: porcentagem da população que será substituída
 - Grande (comum): filhos substituem pais.
 - Pequena: “pais e filhos convivem”.



Parâmetros dos AG's

- Taxa de cruzamento

- Se for muito baixa: busca pode estagnar.
- Se for muito alta: boas estruturas podem ser perdidas.

- Taxa de mutação.

- Possibilita que qualquer ponto do espaço de busca seja atingido.
- Se for muito alta: busca aleatória.



Exemplo: jogo de tênis

- Utilizando apenas os atributos aparência e vento para o aprendizado de regras:
 - Aparência pode ter os valores “sol”, “chuva” ou “nublado”: codificação de 3 possibilidades (portanto, 3 bits).
 - 100 → sol, 010 → chuva, 001 → nublado, 110 → sol ou chuva, etc.
 - Vento pode ter os valores “forte” e “fraco”: codificação de 2 possibilidades.
 - 10 → forte, 01 → fraco, 11 → forte ou fraco



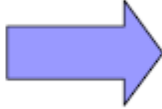
Exemplo: jogo de tênis

- A classe pode ser jogar ou não_jogar tênis: 2 possibilidades
 - 10 → jogar tênis, 01 → não jogar
- Uma hipótese inicial (dentre várias) para os dados de treinamento pode ser:
 - Se vento=forte então classe=não_jogar



Exemplo: jogo de tênis

- A codificação da hipótese pode ser:

Aparência	Vento	Classe		1111001
111	10	01		

- Todos os atributos da regra devem estar representados.
- Após evolução, pode acontecer da classe ser 11, o que não é permitido.
 - Solução: mudança da codificação.
 - Classe 0 ou 1 (jogar ou não).



Exemplo: jogo de tênis

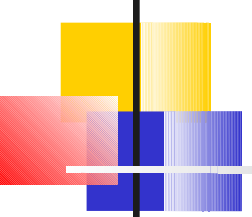
- A função de aptidão pode ser o erro das hipóteses em um conjunto de dados (teste).
- O critério de parada pode ser a taxa de acerto desejada sobre o conjunto de dados.



Exercício

- Represente, em cromossomos, duas hipóteses simbólicas (regras) arbitrárias para classificar o seguinte conjunto de dados. Quais seriam os valores da função de aptidão para cada uma delas?

Personagem	Arma	Sofre transformação	Idade	Classe (herói ou vilão)
He-Man	Lâmina	Sim	Adulto	Herói
Seiya	Magia	Não	Novo	Herói
Mun-ra	Magia	Sim	Velho	Vilão
Bob Esponja	Não_usa	Não	Novo	Herói
Magneto	Não_usa	Não	Adulto	Vilão
Gargamel	Magia	Não	Adulto	Vilão
Wolverine	Lâmina	Não	Velho	Herói
Lex Luthor	Não_usa	Não	Velho	Vilão
Nazaré	Lâmina	Sim	Velho	Vilão
Superman	Não_usa	Sim	Adulto	Herói

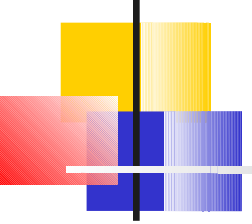


Exercício - Solução

- Passo 1: Definir o cromossomo que irá representar cada hipótese:

Arma			Transformação		Idade			Classe
lâmina	magia	não_usa	Sim	Não	Novo	Adulto	Velho	classe

- Assim são necessários 9 bits para representar as possíveis regras simbólicas para esse conjunto de dados.



Exercício - Solução

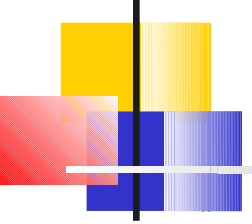
- Passo 2: Representar, em cromossomos, duas hipóteses simbólicas (regras) arbitrárias e seus respectivos valores da função de aptidão.

- Cromossomo 1 (escolhido arbitrariamente):

1	0	1	1	0	0	1	0	1
---	---	---	---	---	---	---	---	---

- Regra representada pelo Cromossomo 1:

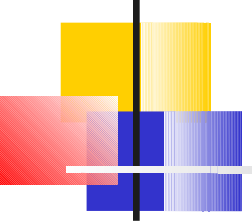
IF((arma=lâmina v arma=não_usa) \wedge (transformação=sim) \wedge (idade=adulto)) Then Classe = Heroi



Exercício - Solução

- Existem dois personagens que são cobertos pela regra representada pelo Cromossomo 1: He-Man e SuperMan.
 - Então o valor da sua função aptidão é igual a 2.
- Cromossomo 2 (escolhido arbitrariamente):
 - Regra representada pelo Cromossomo 2:

IF((arma=magia) \wedge (transformação=não) \wedge (idade=novo \vee idade=velho)) Then Classe = Vilão



Exercício - Solução

- Não existe, no conjunto de dados, personagens que estejam cobertos pela regra representada pelo Cromossomo 2.
 - Então o valor da sua função aptidão é igual a 0.

GA(Fitness, Fitness_threshold, max_geracoes, tampop, Tc, Tm)

tampop: Tamanho da população.

Tc: Taxa de crossover, i.e. a fração da população a ser substituída pelo operador de crossover a cada geração.

Tm: Taxa de mutação, i.e. a fração da população a ser substituída pelo operador de mutação a cada geração.

Inicialize a população: $P \leftarrow$ Geração de hipóteses aleatórias.

Avalie: para cada h in P , compute $\text{Fitness}(h)$.

Enquanto $[\max_h \text{Fitness}(h)] < \text{Fitness_threshold} \mid \text{geração} < \text{max_geracoes}$

1. Seleção: Selecione $(1-Tc)\text{tampop}$ membros de P e adicione a P_{next} .

2. Crossover: Selecione uma porcentagem Tc de pares de hipóteses, $\langle h_1, h_2 \rangle$, produza dois descendentes para cada par, aplicando o operador de crossover, e adicione a P_{next} .

3. Mutação: Escolha aleatoriamente uma porcentagem Tm de indivíduos de P_{next} e inverta um bit selecionado aleatoriamente em cada um desses indivíduos.

4. Atualize: $P \leftarrow P_{\text{next}}$.

5. Avalie: para cada h em P , compute $\text{Fitness}(h)$.

Retorne a hipótese de P que possuir maior função de aptidão.



Exemplo

- Utilização de um AG para encontrar o ponto máximo da função $f(x) = x^2$, sujeita às seguintes restrições:

$$0 \leq x \leq 31$$

x é inteiro

- Parâmetros do AG:
 - Tamanho da população (tampop) = 4
 - Taxa de crossover (T_c) = 0.5
 - Taxa de mutação (T_m) = 0.01
 - Critério de parada: número máximo de gerações (max_geracoes) = 5
 - A função de aptidão [Fitness (h)] será a própria função objetivo.



Exemplo (cont.)

- População inicial (aleatória):

População Inicial {


Cromossomos	x	$f(x)$	Prob. de seleção
A1 = 1 1 0 0 1	25	625	54,5 %
A2 = 0 1 1 1 1	15	225	19,6 %
A3 = 0 1 1 1 0	14	196	17,1 %
A4 = 0 1 0 1 0	10	100	8,7 %

Probabilidade de seleção
proporcional à aptidão

$$p_i = \frac{f(x_i)}{\sum_{k=1}^N f(x_k)}$$

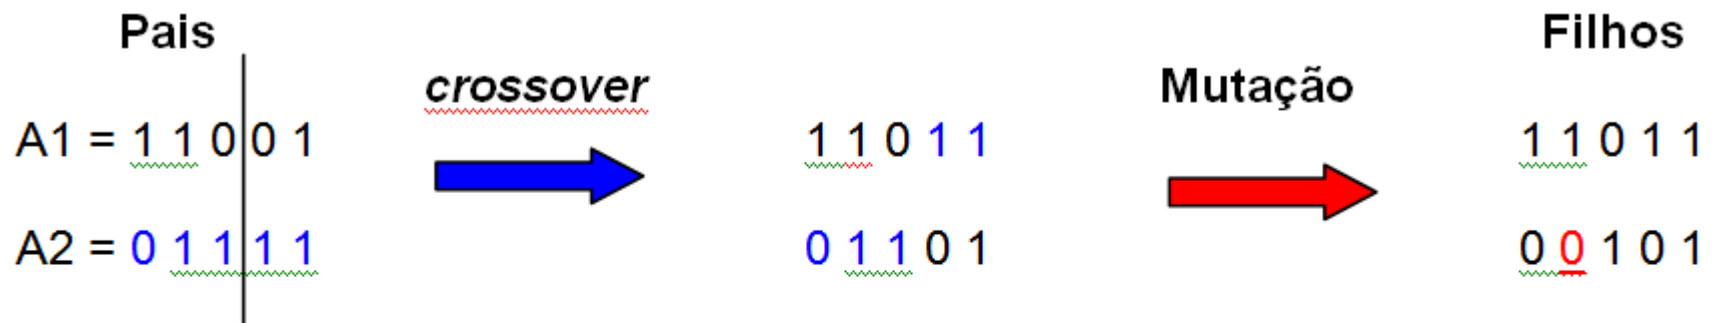
Exemplo (cont.)

- Seleção (proporcional à aptidão):



Exemplo (cont.)

■ Primeira Geração:




Cromossomos	x	$f(x)$	Prob. de seleção
A1 = 1 1 0 0 1	25	625	39,0 %
A2 = 0 1 1 1 1	15	225	14,0 %
A3 = 1 1 0 1 1	27	729	45,4 %
A4 = 0 0 1 0 1	5	25	1,6 %



Exercício

- Continuar o exemplo até o critério de parada (número de gerações = 5) ser atingido.



Leituras

- REZENDE, S.O. Sistemas Inteligentes: Fundamentos e Aplicações. Manole, 2003.
 - Capítulo 9: pp. 225-239.
- MITCHELL, T. Machine Learning. McGraw Hill, 1997.
 - Capítulo 9: pp. 249-258.